

Apostila 5 — Projetos Práticos de Economia

Esta apostila reúne projetos completos que integram tudo que você aprendeu nas Apostilas 1 a 4 (Python, pandas, visualização e econometria). Diferente das apostilas anteriores, ela não está organizada em capítulos de teoria progressiva — está organizada em **projetos independentes**, cada um pensado para virar um item de portfólio, um capítulo de TCC ou uma rotina de trabalho real de um economista.

Cada projeto segue a mesma estrutura: primeiro o **objetivo** (o que o script resolve e por que alguém pagaria ou publicaria por isso), depois a **fundamentação teórica** (o modelo econômico por trás do código — sem entender essa parte, o script vira uma caixa-preta que produz números sem significado), depois um pequeno bloco “**Antes de rodar**” com perguntas conceituais que você deveria conseguir responder *antes* de apertar “executar” (se você não consegue prever ao menos o sinal do resultado, o modelo ainda não foi entendido — só copiado), e só então o **script completo**, comentado, seguido de um **Desafio** para você estender o projeto sozinho, sem solução fornecida.

O Projeto 8, ao final, foge um pouco desse padrão: é uma lista de exercícios curtos e pontuais — não projetos inteiros — para praticar conceitos específicos das apostilas anteriores em dados reais, um de cada vez.

Projeto 1 — Dashboard Macroeconômico do Brasil

Objetivo

Criar um script que baixa, analisa e gera um relatório completo com os principais indicadores.

Indicadores

Variável	Código BCB
IPCA (mensal)	433
SELIC (meta)	11
Desemprego	24369
Câmbio (USD)	1
PIB mensal	4380

Fundamentação teórica

Um dashboard macroeconômico não é uma coleção arbitrária de gráficos — cada indicador escolhido corresponde a uma peça de um arcabouço teórico específico, e o valor de colocá-los lado a lado é deixar visíveis os canais de transmissão que os conectam.

IPCA e a mensuração da inflação. O IPCA (Índice de Preços ao Consumidor Amplo) mede a variação de preços de uma cesta consumida pelas famílias urbanas de renda entre 1 e 40 salários mínimos — é o índice-alvo do regime de metas de inflação brasileiro. A inflação acumulada em 12 meses **não** é a soma simples das taxas mensais (como o script calcula, de forma aproximada, com `.rolling(12).sum()`), e sim o produto encadeado, já que inflação composta funciona como juros compostos aplicados a preços:

$$\text{IPCA}_{12m} = \left[\prod_{i=1}^{12} (1 + \pi_i) \right] - 1$$

onde π_i é a inflação do mês i em proporção (não em %). Para taxas mensais pequenas, a soma simples é uma boa aproximação de primeira ordem — mas em ambientes de inflação mais alta a diferença entre soma e produto deixa de ser desprezível (voltamos a isso no Desafio).

Juro real e a equação de Fisher. A SELIC é a taxa de juros nominal de política monetária; o que importa para decisões de consumo e investimento é o juro real, o retorno depois de descontada a perda de poder de compra da moeda. A relação exata entre as três variáveis é a equação de Fisher:

$$(1 + i) = (1 + r)(1 + \pi^e)$$

Isolando o juro real r :

$$r = \frac{1 + i}{1 + \pi^e} - 1$$

O script usa a aproximação linear $r \approx i - \pi^e$ (a variável `JURO_REAL`), válida quando i e π^e são pequenos — o termo de segunda ordem $r \cdot \pi^e$ se torna desprezível. É a mesma aproximação e o mesmo trade-off vistos na Apostila 1 (Capítulo 5) e retomados com rigor na Apostila 6.

Desemprego, câmbio e a leitura conjunta. O desemprego é o principal indicador do lado real da economia — junto ao hiato do produto (Projeto 5), é a variável que a política monetária tenta estabilizar sem gerar inflação excessiva, o trade-off por trás da Curva de Phillips (Apostila 4). O câmbio nominal conecta a economia doméstica ao resto do mundo: uma desvalorização cambial pressiona a inflação via preços de importados (o *pass-through* cambial) e afeta a competitividade externa — e episódios extremos de pressão cambial são o objeto do Projeto 6.

Um dashboard bem desenhado deixa visível essa cadeia causal: câmbio $\rightarrow$ inflação $\rightarrow$ juro (via regra de política monetária) $\rightarrow$ hiato do produto/desemprego $\rightarrow$ e de volta à inflação, fechando o ciclo de transmissão da política monetária.

Dois indicadores derivados que valem a pena conhecer. Embora não estejam no script, dois índices simples costumam complementar um dashboard como este, e são bons candidatos para o Desafio:

- **Índice de Miséria** (Okun, 1962): $IM_t = \pi_t + u_t$, a soma simples da inflação e da taxa de desemprego — uma medida informal (não derivada de um modelo formal de bem-estar) de quanto “desconfortável” está a situação macroeconômica para o cidadão médio.
- **Lei de Okun** (Okun, 1962): relaciona variações no hiato do produto a variações na taxa de desemprego, $u_t - u_{t-1} \approx -\kappa (g_t - g^*)$, onde g_t é o crescimento do PIB, g^* a taxa de crescimento potencial e $\kappa > 0$ um coeficiente empírico (tipicamente entre 0,3 e 0,5 nos EUA; a magnitude varia bastante entre países e é objeto de estimação própria no caso brasileiro).

Um trecho de código isolado ajuda a fixar a diferença entre a aproximação linear de Fisher e a fórmula exata, discutidas acima:

```
def juro_real_exato(selic_pct, ipca_pct):
    i, pi = selic_pct / 100, ipca_pct / 100
    return ((1 + i) / (1 + pi) - 1) * 100

def juro_real_aproximado(selic_pct, ipca_pct):
    return selic_pct - ipca_pct

# Com SELIC = 13,25% e IPCA acumulado = 4,50%:
print(juro_real_exato(13.25, 4.50))      # ~8,37%
print(juro_real_aproximado(13.25, 4.50)) # 8,75%
```

A diferença de quase 0,4 p.p. entre os dois números acima, num cenário de juros bem mais altos que a inflação, é o tipo de erro que se acumula de forma relevante num relatório que reporta juro real mês a mês.

Antes de rodar

- Dado o cenário macroeconômico atual do Brasil, você espera que o juro real (SELIC menos IPCA acumulado) esteja positivo ou negativo? O que isso sugere sobre a postura da política monetária (contracionista vs. expansionista)?
- Se o câmbio se desvalorizasse 10% em um único mês, qual dos outros indicadores do dashboard você esperaria reagir primeiro, e com que defasagem aproximada (meses)?

Script completo

```
from bcb import sgs
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker

# 1. BAIXAR DADOS
codigos = {
    "IPCA": 433,
    "SELIC": 11,
    "DESEMPREGO": 24369,
    "CAMBIO": 1,
    "PIB": 4380
}

dados = sgs.get(codigos, start="2010-01-01")

# 2. PROCESSAR
# Inflação acumulada 12 meses
dados["IPCA_ACUM"] = dados["IPCA"].rolling(12).sum()

# Juro real
dados["JURO_REAL"] = dados["SELIC"] - dados["IPCA_ACUM"]

# Variação do câmbio
dados["CAMBIO_VAR"] = dados["CAMBIO"].pct_change() * 100

# 3. RELATÓRIO TEXTO
print("=" * 60)
print("RELATÓRIO MACROECONÔMICO - BRASIL")
print("=" * 60)

ultimos = dados.tail(1)
print(f"\n📅 Referência: {ultimos.index[0].date()}")
print(f"\n📌 INFLAÇÃO")
print(f"    IPCA mensal: {ultimos['IPCA'].values[0]:.2f}%")
print(f"    IPCA acum. 12m: {ultimos['IPCA_ACUM'].values[0]:.2f}%")

print(f"\n📌 JUROS")
print(f"    SELIC: {ultimos['SELIC'].values[0]:.2f}%")
print(f"    Juro real: {ultimos['JURO_REAL'].values[0]:.2f}%")

print(f"\n📌 MERCADO DE TRABALHO")
print(f"    Desemprego: {ultimos['DESEMPREGO'].values[0]:.2f}%")
```

```

print(f"\n 📌 CÂMBIO")
print(f"    USD/BRL: {ultimos['CAMBIO'].values[0]:.2f}")

# 4. GRÁFICOS
fig, axes = plt.subplots(3, 2, figsize=(14, 10))
axes = axes.flatten()

titulos = [
    ("IPCA (mensal)", "crimson"),
    ("SELIC", "navy"),
    ("IPCA Acum. 12m", "darkred"),
    ("Desemprego", "darkgreen"),
    ("Câmbio (USD/BRL)", "purple"),
    ("Juro Real", "orange")
]

for ax, (titulo, cor), (_, serie) in zip(axes, titulos, dados[titulos]):
    ax.plot(dados.index, serie, color=cor, linewidth=1.2)
    ax.set_title(titulo, fontsize=12, fontweight="bold")
    ax.grid(True, alpha=0.3)

fig.delaxes(axes[5]) # remove último (vazio)
fig.tight_layout()
fig.savefig("dashboard_macro.png", dpi=200, bbox_inches="tight")
plt.close()

print(f"\n 📁 Dashboard salvo: dashboard_macro.png")

```

Desafio

Adicione mais 2 indicadores de sua escolha (pesquise códigos no site do BCB SGS).

Projeto 2 — Análise de Convergência de Renda

Objetivo

Testar a hipótese de β -convergência: países pobres crescem mais rápido que países ricos.

Fundamentação teórica

A hipótese de convergência de renda deriva do modelo de crescimento de Solow-Swan (Solow, 1956), no qual o produto por trabalhador em estado estacionário é determinado por parâmetros estruturais (taxa de poupança s , depreciação δ , crescimento populacional n , progresso tecnológico g) — não pelo nível inicial de capital. A intuição: economias com menos capital por trabalhador têm produtividade marginal do capital mais alta (retornos marginais decrescentes) e por isso crescem mais rápido até convergir ao seu estado estacionário.

Função de produção e acumulação de capital. O modelo parte de uma função de produção neoclássica com retornos constantes de escala, tipicamente Cobb-Douglas, $Y = K^\alpha (AL)^{1-\alpha}$ com $0 < \alpha < 1$. Em termos per capita efetivo ($k = K/AL$, $y = Y/AL = k^\alpha$), a acumulação de capital segue:

$$\dot{k} = s k^\alpha - (n + g + \delta) k$$

Perto do estado estacionário k^* (onde $\dot{k} = 0$), a linearização dessa equação diferencial mostra que a velocidade de convergência é aproximadamente constante e proporcional à distância até o estado

estacionário — esse é o fundamento microeconômico por trás da equação de β -convergência testada empiricamente.

β -convergência (absoluta). A forma reduzida, testável com uma regressão simples, relaciona o crescimento médio do PIB per capita entre dois períodos ao $\log$ do PIB per capita inicial:

$$g_{i,[0,T]} = \alpha + \beta \ln(y_{i,0}) + \varepsilon_i, \quad g_{i,[0,T]} = \frac{1}{T} \left(\ln \frac{y_{i,T}}{y_{i,0}} \right)$$

A convergência absoluta é confirmada se $\hat{\beta} < 0$ e estatisticamente significativo: países que partiram mais pobres cresceram mais rápido. É exatamente essa regressão que `sm.OLS` estima no script. Da teoria de Solow linearizada, deriva-se uma relação entre β e a velocidade de convergência λ :

$$\beta \approx -(1 - e^{-\lambda T}) \Rightarrow \lambda = -\frac{\ln(1 + \beta)}{T}$$

Um λ próximo de 2% ao ano é o resultado clássico de Barro e Sala-i-Martin (1992) em países e regiões — a chamada “regra dos 2%”.

Exemplo numérico. Suponha que a regressão do script produza $\hat{\beta} = -0,015$ para uma janela de $T = 20$ anos (o mesmo horizonte 2000–2020 usado no código). A velocidade de convergência implícita seria $\lambda = -\ln(1 - 0,015)/20 \approx 0,00076$, ou cerca de 0,076% ao ano — bem abaixo da “regra dos 2%”, o que sinalizaria convergência extremamente lenta (o hiato entre países ricos e pobres levaria séculos para se fechar pela metade). Comparar o λ implícito do seu resultado com esse benchmark de 2% é uma forma rápida de julgar se a magnitude encontrada é economicamente relevante, e não apenas estatisticamente significativa. Em código:

```
import numpy as np

def velocidade_convergencia(beta, T):
    """beta: coeficiente estimado da regressão; T: horizonte em anos."""
    return -np.log(1 + beta) / T

lam = velocidade_convergencia(beta=-0.015, T=20)
print(f"lambda = {lam:.5f} ({lam*100:.3f}% ao ano)")
```

Convergência absoluta vs. condicional. A regressão simples testa convergência *absoluta*: a previsão de que todo país convergiria para o mesmo nível de renda per capita de longo prazo — hipótese fortemente rejeitada em amostras heterogêneas de países ricos e pobres. A resposta da literatura é a convergência *condicional*: cada país converge para o seu **próprio** estado estacionário, condicional a variáveis de controle (poupança, educação, instituições):

$$g_{i,[0,T]} = \alpha + \beta \ln(y_{i,0}) + \gamma' X_i + \varepsilon_i$$

Nesse caso, $\hat{\beta} < 0$ é esperado mesmo sem convergência a um nível comum — apenas a trajetórias paralelas em $\log$. Sem a variável de controle, a regressão do script mistura os dois conceitos.

σ -convergência. Um conceito distinto, por vezes confundido com β -convergência, é a redução ao longo do tempo da dispersão (desvio-padrão) da renda per capita em $\log$ entre os países da amostra: $\sigma_t = \text{dp}[\ln(y_{i,t})]_i$. Há σ -convergência se $\sigma_T < \sigma_0$. É possível ter β -convergência sem σ -convergência — choques idiossincráticos podem ampliar a dispersão mesmo que, em média, os pobres cresçam mais rápido. Esse fenômeno é por vezes chamado de “falácia de Galton” aplicada a crescimento, em referência à regressão à média observada originalmente por Francis Galton em alturas de pais e filhos.

Uma ressalva sobre o script. O código usa dados **simulados aleatoriamente**

(`np.random.uniform`) apenas para fins didáticos — qualquer padrão de convergência encontrado no exemplo é artefato do gerador aleatório, não um fato sobre a economia mundial. Para uma análise real, é necessário substituir os dados simulados pelos dados efetivos do WDI (indicador NY.GDP.PCAP.PP.KD, PIB per capita PPC), como o próprio comentário no código sugere.

Antes de rodar

- Qual sinal você espera para o coeficiente β se a hipótese de convergência absoluta for verdadeira? Se você adicionasse uma variável de controle (ex: taxa de investimento), o que aconteceria com a magnitude do β ao passar de convergência absoluta para condicional?
- Como os dados do script são simulados aleatoriamente (sem relação causal real entre PIB inicial e crescimento), que valor de β você espera obter em expectativa, e por quê?

Dados

Vamos usar o World Development Indicators (WDI) do Banco Mundial.

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
import matplotlib.pyplot as plt
from pandas_datareader import wb # alternativa: baixar CSV manualmente

# Baixar PIB per capita (método alternativo)
# NY.GDP.PCAP.PP.KD = PIB per capita PPP (US$ constantes)
países = ["BRA", "ARG", "CHL", "COL", "PER", "MEX", "URY", "ECU",
          "USA", "CAN", "GBR", "DEU", "FRA", "JPN", "KOR", "CHN",
          "IND", "ZAF", "NGA", "KEN", "ETH", "VNM", "IDN", "PHL",
          "TUR", "RUS", "SAU", "ARE"]

# NOTA: Se pandas_datareader não estiver instalado:
# pip install pandas_datareader
# Se falhar, baixe manualmente de https://data.worldbank.org/

# Vou usar dados simulados para demonstração:
np.random.seed(42)
anos_dados = {país: {"pib_2000": np.random.uniform(1000, 40000),
                    "pib_2020": np.random.uniform(2000, 60000)}}
                for país in países}

df = pd.DataFrame.from_dict(anos_dados, orient="index")
df["crescimento"] = (df["pib_2020"] / df["pib_2000"]) ** (1/20) - 1
df["crescimento"] *= 100 # em %
df["log_pib_2000"] = np.log(df["pib_2000"])

#  $\beta$ -convergência: crescimento  $\sim \beta * \log(\text{PIB inicial})$ 
X = sm.add_constant(df["log_pib_2000"])
y = df["crescimento"]

modelo = sm.OLS(y, X).fit()
print("TESTE DE  $\beta$ -CONVERGÊNCIA")
print("=" * 40)
print(modelo.summary())

# Coeficiente  $\beta$  negativo confirma convergência
beta = modelo.params["log_pib_2000"]
```

```

print(f"\nβ = {beta:.4f}")
if beta < 0 and modelo.pvalues["log_pib_2000"] < 0.05:
    print("✅ Evidência de β-convergência (pobres crescem mais rápido)")
else:
    print("❌ Sem evidência de convergência")

# Gráfico
fig, ax = plt.subplots(figsize=(10, 6))
ax.scatter(df["log_pib_2000"], df["crescimento"], alpha=0.6, edgecolors="black")
ax.plot(df["log_pib_2000"], modelo.fittedvalues, color="red", linestyle="--")

ax.set_xlabel("Log PIB per capita (2000)")
ax.set_ylabel("Crescimento médio anual (%) 2000-2020")
ax.set_title("β-Convergência: Países Pobres Crescem Mais?")
ax.grid(True, alpha=0.3)
fig.tight_layout()
fig.savefig("convergencia.png", dpi=150)

```

Desafio

Substitua os dados simulados por dados reais do WDI (NY.GDP.PCAP.PP.KD, 2000 vs. 2020, para os mesmos países). Refaça a regressão e verifique se a hipótese de convergência absoluta se sustenta. Em seguida, adicione uma variável de controle (ex: taxa de investimento ou escolaridade média) e compare o β estimado antes e depois — a magnitude aumentou ou diminuiu?

Projeto 3 — Curva de Kuznets Ambiental

Objetivo

Testar se a relação entre PIB per capita e emissões de CO₂ tem forma de U invertido.

Fundamentação teórica

A Curva de Kuznets Ambiental (Environmental Kuznets Curve, EKC) é uma hipótese proposta por Grossman e Krueger (1991, 1995), a partir de uma analogia com a curva de Kuznets original (Kuznets, 1955, sobre desigualdade de renda e desenvolvimento), segundo a qual a relação entre renda per capita e degradação ambiental tem formato de **U invertido**: a poluição cresce nos estágios iniciais de industrialização e cai depois que o país atinge um determinado nível de renda.

Os três canais por trás da hipótese (Grossman & Krueger, 1995; Panayotou, 2000):

1. **Efeito escala** (*scale effect*): mais produção, tudo o mais constante, significa mais uso de recursos e mais poluição — efeito positivo sobre emissões.
2. **Efeito composição** (*composition effect*): à medida que a renda cresce, a estrutura da economia se desloca de agricultura para indústria (mais poluente) e depois para serviços (menos poluente).
3. **Efeito técnica** (*technique effect*): renda mais alta financia tecnologias mais limpas e gera demanda por regulação ambiental mais rígida — qualidade ambiental é, em parte, um bem de luxo, com elasticidade-renda da demanda por regulação maior que 1.

A hipótese do U invertido é que, em baixa renda, o efeito escala domina; em renda mais alta, composição e técnica passam a dominar, revertendo a trajetória.

Especificação econométrica. A forma funcional padrão é uma regressão quadrática de emissões per capita sobre o PIB per capita (o script usa níveis, não logs, mas a lógica é idêntica):

$$\text{CO}_2 = \beta_0 + \beta_1 \text{PIB} + \beta_2 \text{PIB}^2 + \varepsilon$$

A hipótese de U-invertido corresponde a $\beta_1 > 0$ e $\beta_2 < 0$. O **ponto de virada** — o nível de renda em que as emissões atingem o máximo — vem da condição de primeira ordem:

$$\frac{d \text{CO}_2}{d \text{PIB}} = \beta_1 + 2\beta_2 \text{PIB} = 0 \Rightarrow \text{PIB}^* = -\frac{\beta_1}{2\beta_2}$$

É esse cálculo que o script faz com `turning_point = -b1 / (2*b2)`. A condição de segunda ordem ($\beta_2 < 0$) garante que o ponto crítico é um **máximo** — se $\beta_2 > 0$, a curva teria formato de U (não invertido), contradizendo a hipótese.

Log-log vs. níveis. O script do Projeto 3 estima a especificação em **níveis** (PIB e CO₂ em suas unidades originais), que é a forma mais simples de visualizar o U invertido diretamente num gráfico de dispersão. Grande parte da literatura empírica, porém, estima em **log-log** — $\ln(\text{CO}_2) = \beta_0 + \beta_1 \ln(\text{PIB}) + \beta_2 [\ln(\text{PIB})]^2 + \varepsilon$ — porque essa forma funcional lida melhor com a distribuição tipicamente assimétrica (poucos países muito ricos, muitos países pobres) tanto do PIB per capita quanto das emissões, e os coeficientes passam a ter interpretação direta de elasticidade. O ponto de virada, nesse caso, é obtido da mesma forma (derivada igual a zero), mas expresso em log do PIB — depois é preciso desfazer o log ($e^{\ln(\text{PIB}^*)}$) para reportar o valor em dólares.

Críticas à hipótese. A EKC é um dos resultados empíricos mais contestados da economia ambiental: (i) parte da redução de emissões em países ricos reflete deslocamento da produção poluente para países pobres (*pollution haven*), não redução real da pegada de consumo; (ii) a EKC tem suporte mais forte para poluentes locais e imediatos (SO₂, particulados) do que para CO₂, um poluente global cujo custo é diluído entre todos os países; (iii) o ponto de virada estimado costuma ser muito sensível à amostra de países e ao período usado, tornando arriscada qualquer extrapolação para prever o comportamento futuro de países ainda no ramo ascendente.

Antes de rodar

- Para qual tipo de poluente (CO₂ global vs. poluição do ar local) você esperaria uma curva de Kuznets mais nítida, dado os incentivos políticos discutidos acima?
- Os dados simulados já embutem uma relação quadrática ($0.5 \cdot \text{pib} - 0.000006 \cdot \text{pib}^2$). Calcule à mão o ponto de virada teórico exato a partir desses coeficientes antes de rodar a regressão — o valor estimado deveria ser idêntico ou apenas parecido? Por quê?

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
import matplotlib.pyplot as plt

np.random.seed(42)
n = 100

# Simular dados com relação U-invertido
pib_per_capita = np.random.uniform(1000, 50000, n)
# emissões = termo_quadratICO com máximo no meio
emissao = 0.5 * pib_per_capita - 0.000006 * pib_per_capita**2
emissao += np.random.normal(0, 10, n) # ruído
emissao = np.maximum(emissao, 0) # não negativa

df = pd.DataFrame({"pib": pib_per_capita, "co2": emissao})
df["pib2"] = df["pib"] ** 2
df["log_pib"] = np.log(df["pib"])

# Modelo: CO2 = β0 + β1*PIB + β2*PIB2
```

```

X = sm.add_constant(df[["pib", "pib2"]])
y = df["co2"]

modelo = sm.OLS(y, X).fit()
print(modelo.summary())

b1 = modelo.params["pib"]
b2 = modelo.params["pib2"]

if b1 > 0 and b2 < 0:
    # Ponto de virada
    turning_point = -b1 / (2 * b2)
    print(f"\nPonto de virada do PIB per capita: ${turning_point:,.0f}")
    print("✅ Evidência de Curva de Kuznets Ambiental")
else:
    print("❌ Sem evidência de U-invertido")

# Gráfico
fig, ax = plt.subplots(figsize=(10, 6))
ax.scatter(df["pib"], df["co2"], alpha=0.5, edgecolors="black")

# Linha ajustada
x_range = np.linspace(df["pib"].min(), df["pib"].max(), 100)
y_pred = modelo.params["const"] + modelo.params["pib"] * x_range + \
    modelo.params["pib2"] * x_range**2
ax.plot(x_range, y_pred, color="red", linewidth=2, label="Ajuste quadrático")

ax.axvline(turning_point, color="gray", linestyle=":", label=f"Ponto virada:
${turning_point:,.0f}")
ax.legend()
ax.set_xlabel("PIB per capita (US$)")
ax.set_ylabel("Emissões de CO2 per capita")
ax.set_title("Curva de Kuznets Ambiental")
ax.grid(True, alpha=0.3)
fig.tight_layout()
fig.savefig("kuznets.png", dpi=150)

```

Desafio

Substitua os dados simulados por uma série real (ex: emissões de CO₂ per capita vs. PIB per capita PPC de um painel de países, disponível no Our World in Data ou no WDI). O formato de U invertido se mantém com dados reais? Teste também uma especificação cúbica ($\beta_3 \text{ PIB}^3$) e verifique se ela é estatisticamente significativa — isso mudaria sua conclusão sobre a forma da curva?

Projeto 4 — Modelo de Previsão de Inflação

Objetivo

Criar um modelo SARIMA que prevê o IPCA para os próximos 12 meses.

Fundamentação teórica

Prever uma série temporal como o IPCA é fundamentalmente diferente de rodar uma regressão de corte transversal (Projetos 2 e 3): aqui a única “variável explicativa” disponível é o próprio passado da série, e a metodologia dominante é a abordagem Box-Jenkins, formalizada nos modelos ARIMA (AutoRegressive Integrated Moving Average) e sua extensão sazonal, SARIMA.

Os três componentes de um ARIMA(p,d,q).

- **AR(p) – autorregressivo:** o valor atual é combinação linear de seus próprios p valores passados,

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$$

- **I(d) – integração:** número de diferenciações ($\Delta y_t = y_t - y_{t-1}$) necessárias até a série se tornar estacionária.
- **MA(q) – médias móveis:** o valor atual depende de erros (choques) passados, não de valores passados,

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Um SARIMA(p, d, q)(P, D, Q) $_s$ adiciona uma estrutura sazonal análoga, operando sobre múltiplos do período sazonal s (aqui $s = 12$, sazonalidade anual em dados mensais – por exemplo, reajustes concentrados em determinados meses).

Identificando as ordens (p, q): ACF e PACF. Antes de simplesmente “chutar” $(1, d, 1)(1, 1, 1, 12)$ como o script faz por conveniência didática, a metodologia Box-Jenkins clássica identifica p e q examinando dois gráficos da série já estacionária: a **função de autocorrelação** (ACF), $\rho_k = \text{Corr}(y_t, y_{t-k})$, e a **função de autocorrelação parcial** (PACF), que mede a correlação entre y_t e y_{t-k} **líquida** do efeito das defasagens intermediárias $y_{t-1}, \dots, y_{t-k+1}$. A regra prática: um processo AR(p) puro tem PACF que “corta” abruptamente após a defasagem p (e ACF que decai geometricamente); um processo MA(q) puro tem o padrão oposto – ACF corta após q , PACF decai geometricamente. Na prática moderna, é mais comum comparar vários modelos candidatos pelo critério de informação de Akaike (AIC) ou Bayesiano (BIC), que penalizam o ganho de ajuste pelo número de parâmetros – e escolher a especificação com menor critério, em vez de inspecionar ACF/PACF visualmente a cada série. Em código, gerar os dois gráficos é direto:

```
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
import matplotlib.pyplot as plt
```

```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
plot_acf(serie.dropna(), lags=24, ax=axes[0])
plot_pacf(serie.dropna(), lags=24, ax=axes[1])
axes[0].set_title("ACF - IPCA mensal")
axes[1].set_title("PACF - IPCA mensal")
fig.tight_layout()
fig.savefig("acf_pacf_ipca.png", dpi=150)
```

Por que testar estacionariedade antes de tudo: o teste ADF. Um modelo ARIMA só é bem definido sobre uma série estacionária (média e variância constantes no tempo, autocovariância dependendo apenas da defasagem). O teste Aumentado de Dickey-Fuller (ADF) testa a hipótese nula de **raiz unitária** (não estacionariedade) contra a alternativa de estacionariedade, a partir da regressão:

$$\Delta y_t = \alpha + \rho y_{t-1} + \sum_{i=1}^k \delta_i \Delta y_{t-i} + \varepsilon_t$$

A hipótese nula é $H_0 : \rho = 0$; rejeitar H_0 (p-valor baixo) é evidência de estacionariedade. A estatística de teste sob H_0 **não** segue uma distribuição t-Student usual – segue a distribuição não-padrão de Dickey-Fuller, motivo pelo qual `adfuller()` usa valores críticos tabelados separadamente.

Por que a taxa de inflação (e não o índice de preços em nível) costuma já ser estacionária. Séries de preços em nível têm tendência e, portanto, raiz unitária – mas a taxa de inflação mensal,

que já é uma variação percentual, frequentemente é estacionária em torno de uma média (ou próxima disso), o que explica por que o teste do script é aplicado sobre o IPCA mensal diretamente.

Avaliação fora da amostra. Separar treino/teste é essencial porque um modelo pode se ajustar muito bem aos dados de estimação (overfitting) e ainda assim prever mal o futuro. As duas métricas usadas respondem perguntas ligeiramente diferentes:

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t| \quad \text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

MAE está na mesma unidade da série (pontos percentuais de IPCA); MAPE é adimensional (%), o que facilita comparar séries de escalas diferentes, mas se torna instável quando y_t está próximo de zero — um problema real ao prever IPCA mensal, que ocasionalmente passa perto de 0%.

Antes de rodar

- Você espera que a série de IPCA mensal (taxa mês a mês, não o índice acumulado) seja estacionária ou não? Justifique com a definição de estacionariedade.
- Por que faz mais sentido reservar os últimos 12 meses como teste do que escolher 12 meses aleatórios no meio da amostra?

```
from bcb import sgs
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.stattools import adfuller
import warnings
warnings.filterwarnings("ignore")

# 1. DADOS
ipca = sgs.get({"IPCA": 433}, start="2005-01-01")
serie = ipca["IPCA"]

# 2. TESTE DE ESTACIONARIEDADE
result = adfuller(serie.dropna())
print(f"ADF p-valor: {result[1]:.4f}")
if result[1] > 0.05:
    d = 1
    print("Série não estacionária → diferenciando (d=1)")
else:
    d = 0
    print("Série estacionária (d=0)")

# 3. SEPARAR TREINO/TESTE
train = serie[:-12]
test = serie[-12:]

# 4. SARIMA
# Ordem: (p, d, q) x (P, D, Q, s)
# s=12 para sazonalidade anual
modelo = SARIMAX(train,
                  order=(1, d, 1),
                  seasonal_order=(1, 1, 1, 12),
                  enforce_stationarity=False,
                  enforce_invertibility=False)
```

```

resultado = modelo.fit(dis=False)
print(resultado.summary())

# 5. PREVISÃO
forecast = resultado.forecast(steps=12)

# 6. AVALIAÇÃO
from sklearn.metrics import mean_absolute_error, mean_absolute_percentage_error

mae = mean_absolute_error(test, forecast)
mape = mean_absolute_percentage_error(test, forecast)

print(f"\n📊 AVALIAÇÃO DO MODELO")
print(f"Erro médio absoluto (MAE): {mae:.2f} pp")
print(f"Erro percentual (MAPE): {mape:.2f}%")

# 7. GRÁFICO
fig, ax = plt.subplots(figsize=(12, 5))
ax.plot(train.index[-60:], train[-60:], label="Histórico", linewidth=1.5)
ax.plot(test.index, test, label="Real", color="green", linewidth=1.5)
ax.plot(forecast.index, forecast, label="Previsão", color="red", linestyle="--",
        linewidth=1.5)
ax.fill_between(forecast.index,
                resultado.get_forecast(12).conf_int().iloc[:, 0],
                resultado.get_forecast(12).conf_int().iloc[:, 1],
                alpha=0.2, color="red", label="IC 95%")

ax.legend()
ax.set_title("Previsão IPCA - SARIMA(1,1,1)(1,1,1,12)")
ax.set_ylabel("IPCA mensal (%)")
ax.grid(True, alpha=0.3)
fig.tight_layout()
fig.savefig("previsao_ipca.png", dpi=150)
plt.close()

print("\n📁 Gráfico salvo: previsao_ipca.png")
print("\nPrevisões:")
for data, valor in zip(forecast.index, forecast.values):
    print(f"   {data.date():} {valor:.2f}%")

```

Desafio

Compare o SARIMA do script com um modelo auto-selecionado (ex: `pmdarima.auto_arima`) e com um modelo ingênuo de referência (*naive forecast*, prever que o próximo valor será igual à média dos últimos 12 meses). O SARIMA supera o modelo ingênuo em MAE/MAPE fora da amostra? Um modelo sofisticado que não supera uma referência simples é um resultado importante — não descarte essa possibilidade.

Projeto 5 — Regra de Taylor

Objetivo

Estimar a regra de Taylor para o Brasil: SELIC resposta à inflação e ao hiato do produto.

Fundamentação teórica

A regra de Taylor (Taylor, 1993) é a formalização mais influente de como um banco central deveria (ou efetivamente costuma) ajustar sua taxa de juros de curto prazo em resposta a desvios da inflação em relação à meta e do produto em relação ao seu potencial:

$$i_t = r^* + \pi_t + \phi_\pi(\pi_t - \pi^*) + \phi_y(y_t - y_t^*)$$

onde i_t é a taxa de juros nominal de curto prazo (a SELIC), r^* é a taxa de juros real de equilíbrio (“neutra”), π_t é a inflação corrente (ou esperada) e π^* a meta, $y_t - y_t^*$ é o hiato do produto (PIB efetivo menos potencial, em %), e ϕ_π , ϕ_y são os coeficientes de reação do banco central. Taylor (1993) propôs $\phi_\pi = 0,5$ e $\phi_y = 0,5$ com base em dados dos EUA — não derivados de otimização formal, mas como regra simples que descrevia bem o Fed da época.

O Princípio de Taylor. Para a regra estabilizar a inflação (evitar espirais auto-realizáveis), o banco central precisa reagir *mais que proporcionalmente* a desvios da inflação: $\phi_\pi > 1$. A intuição: se $\phi_\pi < 1$, a SELIC nominal sobe menos que a própria inflação quando esta se acelera — o juro **real** cai, estimulando ainda mais demanda e realimentando a inflação (instabilidade). Com $\phi_\pi > 1$, o juro real sobe quando a inflação sobe, contendo a demanda. Esse resultado é conhecido como **Princípio de Taylor**.

Suavização da taxa de juros. Bancos centrais raramente saltam para o nível “ótimo” segundo a regra — movem-se gradualmente, em passos pequenos e persistentes. Isso é capturado acrescentando a taxa defasada como regressor:

$$i_t = (1 - \rho) i_t^{\text{regra}} + \rho i_{t-1} + \eta_t$$

com $\rho \in (0, 1)$ medindo o grau de suavização. O script cria `selic_lag1` para permitir esse tipo de especificação, embora a regressão principal, por simplicidade didática, estime a versão sem suavização.

O filtro Hodrick-Prescott (HP) e o hiato do produto. O hiato não é diretamente observável — requer estimar o PIB “potencial” (tendência de longo prazo). O filtro HP decompõe y_t em tendência τ_t e ciclo $c_t = y_t - \tau_t$, minimizando:

$$\min_{\{\tau_t\}} \sum_{t=1}^T (y_t - \tau_t)^2 + \lambda \sum_{t=2}^{T-1} [(\tau_{t+1} - \tau_t) - (\tau_t - \tau_{t-1})]^2$$

O primeiro termo penaliza o ciclo; o segundo penaliza mudanças na inclinação da tendência. O parâmetro λ controla o trade-off: $\lambda \rightarrow 0$ faz a tendência seguir os dados perfeitamente; $\lambda \rightarrow \infty$ força uma tendência linear. O valor $\lambda = 14400$ do script é a convenção de Hodrick e Prescott (1997) para dados **mensais** (para trimestrais, a convenção é $\lambda = 1600$; para anuais, $\lambda = 100$) — um detalhe frequentemente esquecido que muda substancialmente o resultado se aplicado com o λ errado.

Uma ressalva conhecida. O filtro HP sofre de viés de borda (*end-point bias*): a tendência estimada nos últimos períodos da amostra é instável e tende a ser revisada para trás à medida que novos dados chegam — o hiato estimado para o mês mais recente é o menos confiável de toda a série, um problema relevante ao interpretar a regra de Taylor em tempo real.

Dados em tempo real vs. dados revisados. Uma crítica influente de Orphanides (2001) mostrou que regras de Taylor estimadas com dados **revisados** (como os que o script baixa hoje, já ajustados por revisões posteriores do IBGE/BCB) podem indicar decisões de política monetária muito diferentes das que o banco central via **no momento da decisão**, com os dados preliminares então disponíveis. Isso é especialmente relevante para o hiato do produto: a estimativa do PIB potencial em

tempo real é sistematicamente menos precisa do que a estimativa feita anos depois, quando mais dados estão disponíveis — um lembrete de que “replicar” a regra de Taylor de um período passado usando dados de hoje não é o mesmo que reconstruir a informação que o Copom realmente tinha em mãos.

Antes de rodar

- Qual sinal você espera para o coeficiente de `ipca_acum` na regra estimada? Segundo o Princípio de Taylor, que magnitude sinalizaria uma política monetária estabilizadora?
- Por que a escolha de $\lambda = 14400$ (em vez de 1600) importa neste script especificamente? O que aconteceria com o hiato estimado se você usasse o λ errado para a periodicidade dos dados?

```
from bcb import sgs
import pandas as pd
import statsmodels.api as sm
import matplotlib.pyplot as plt

# SELIC (11), IPCA acum 12m (13522), PIB (4380)
selic = sgs.get({"SELIC": 11}, start="2005-01-01")
ipca_acum = sgs.get({"IPCA_ACUM": 13522}, start="2005-01-01")
pib = sgs.get({"PIB": 4380}, start="2005-01-01")

df = pd.merge(selic, ipca_acum, on="Date")
df = pd.merge(df, pib, on="Date").dropna()
df.columns = ["selic", "ipca_acum", "pib"]

# Hiato do produto (desvio da tendência)
# Usando filtro HP
from statsmodels.tsa.filters.hp_filter import hpfilter
cycle, trend = hpfilter(df["pib"], lamb=14400)
df["hiato"] = cycle

# SELIC defasada (suavização)
df["selic_lag1"] = df["selic"].shift(1)

df = df.dropna()

# Regra de Taylor:  $SELIC = \beta_0 + \beta_1 \cdot \text{inflação} + \beta_2 \cdot \text{hiato}$ 
X = sm.add_constant(df[["ipca_acum", "hiato"]])
y = df["selic"]

modelo = sm.OLS(y, X).fit()
print("REGRAS DE TAYLOR - BRASIL")
print("=" * 40)
print(modelo.summary())

# SELIC prevista vs real
df["selic_prevista"] = modelo.fittedvalues

fig, ax = plt.subplots(figsize=(12, 5))
ax.plot(df.index, df["selic"], label="SELIC real", color="navy", linewidth=1.5)
ax.plot(df.index, df["selic_prevista"], label="SELIC prevista (Taylor)",
        color="crimson", linestyle="--", linewidth=1.5)
ax.legend()
ax.set_title("Regra de Taylor - Brasil")
ax.set_ylabel("SELIC (%)")
ax.grid(True, alpha=0.3)
```

```
fig.tight_layout()
fig.savefig("regra_taylor.png", dpi=150)
plt.close()

print("\n📁 Gráfico salvo: regra_taylor.png")
```

Desafio

Adicione um termo de suavização (`selic_lag1`) à regressão e reestime. O coeficiente ρ implícito é alto ou baixo? Compare o ajuste (R^2) do modelo com e sem suavização, e discuta se a regra estimada é mais compatível com um Copom que reage rápido ou gradualmente.

Projeto 6 — Análise de Crise Cambial

Objetivo

Identificar períodos de crise cambial usando pressão no mercado de câmbio.

Fundamentação teórica

Crises cambiais são momentos em que a moeda de um país sofre ataque especulativo ou desvalorização abrupta, forçando o banco central a escolher entre deixar a moeda depreciar ou queimar reservas internacionais para defendê-la. A dificuldade de identificar uma “crise” objetivamente — não existe um evento discreto e inequívoco — motivou a construção de índices contínuos de **pressão no mercado de câmbio** (Exchange Market Pressure, EMP), que capturam estresse cambial mesmo quando o banco central evita uma desvalorização visível via intervenção.

A lógica do índice EMP. A ideia, de Gorton e Roper (1977) e refinada por Eichengreen, Rose e Wyplosz (1996), é que a pressão especulativa contra uma moeda se manifesta de duas formas observáveis e *substitutáveis* do ponto de vista do banco central: (i) desvalorização cambial efetiva, se ele deixa a moeda flutuar; ou (ii) perda de reservas internacionais, se ele intervém vendendo dólares para segurar o câmbio. Um índice que olhasse só para a variação cambial subestimaria a pressão em episódios em que o banco central “aguentou o tranco” gastando reservas. A formulação clássica combina as duas variáveis:

$$EMP_t = \frac{\Delta e_t}{e_{t-1}} - \frac{1}{\sigma_{\Delta r}} \cdot \frac{\Delta r_t}{r_{t-1}}$$

onde e_t é a taxa de câmbio nominal e r_t as reservas internacionais. A normalização pelo desvio-padrão de cada componente é necessária porque variações cambiais e de reservas têm escalas e volatilidades muito diferentes — sem ela, o componente mais volátil dominaria o índice artificialmente. O script simplifica essa normalização, dividindo apenas o termo de reservas pelo desvio-padrão da própria série.

Definindo “crise” a partir de um índice contínuo. Como o EMP é uma variável contínua, é preciso uma regra para transformá-lo em evento binário. A convenção mais usada (Eichengreen, Rose & Wyplosz, 1996; Kaminsky & Reinhart, 1999) é marcar como crise qualquer observação que ultrapasse a média histórica por uma margem de 1,5 a 3 desvios-padrão:

$$Crise_t = \mathbb{1} [EMP_t > \overline{EMP} + k \cdot \sigma_{EMP}], \quad k \in [1, 5, 3]$$

O script usa $k = 2$ — um parâmetro de julgamento, não um valor “correto” derivado de teoria: k menor identifica mais episódios (inclusive falsos positivos); k maior é mais conservador, mas pode deixar passar crises reais.

Um exemplo numérico simplificado. Suponha que, em um mês, o câmbio se desvalorizou 3% ($\Delta e/e_{t-1} = 0,03$) enquanto as reservas caíram 1% ($\Delta r/r_{t-1} = -0,01$), e que o desvio-padrão histórico da variação de reservas seja $\sigma_{\Delta r} = 0,02$ (2%). O índice fica $EMP = 0,03 - \frac{1}{0,02} \times (-0,01) = 0,03 + 0,5 = 0,53$, um valor bem acima de um mês “normal” (em que ambos os componentes ficam próximos de zero) — ilustrando como uma queda de reservas relativamente pequena, mas grande frente à sua própria volatilidade histórica, pode contribuir tanto para o índice quanto uma desvalorização cambial notável.

```
def emp_simplificado(delta_e_pct, delta_r_pct, sigma_delta_r_pct):
    """Todos os argumentos em proporção (ex: 0.03 para 3%)."""
    return delta_e_pct - (delta_r_pct / sigma_delta_r_pct)

print(emp_simplificado(0.03, -0.01, 0.02)) # 0.53
```

Modelos teóricos de crise cambial (contexto). A literatura distingue três “gerações”: **primeira geração** (Krugman, 1979), em que a crise resulta de fundamentos fiscais insustentáveis e o colapso do câmbio fixo é previsível; **segunda geração** (Obstfeld, 1994, 1996), em que a crise pode ocorrer mesmo com fundamentos razoáveis, por **múltiplos equilíbrios auto-realizáveis** (um ataque coordenado se torna racional se investidores acreditam que outros vão atacar); **terceira geração** (Krugman, 1999, pós-crise asiática de 1997), que incorpora fragilidade bancária e descasamento de moedas (dívida em dólar, receita em moeda local) como canal adicional de instabilidade. O índice EMP não distingue entre essas causas — é uma ferramenta de **datação** de episódios de estresse, não um teste de qual modelo está correto.

Antes de rodar

- Quantos episódios de crise cambial brasileira você consegue identificar no período coberto pelos dados (desde 2000)? Você espera que o índice EMP capture esses episódios conhecidos?
- Se você aumentasse o limiar de $k = 2$ para $k = 3$ desvios-padrão, o número de períodos classificados como “crise” aumentaria ou diminuiria? Por quê?

```
from bcb import sgs
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# Câmbio (1) e Reservas (3546)
cambio = sgs.get({"CAMBIO": 1}, start="2000-01-01")
reservas = sgs.get({"RESERVAS": 3546}, start="2000-01-01")

df = pd.merge(cambio, reservas, on="Date").dropna()
df.columns = ["cambio", "reservas"]

# Variação cambial
df["cambio_var"] = df["cambio"].pct_change() * 100

# Índice de Pressão Cambial (EMP)
# Combina desvalorização cambial + perda de reservas
df["reservas_var"] = df["reservas"].pct_change() * 100
df["emp"] = df["cambio_var"] - df["reservas_var"] / df["reservas"].std()

# Identificar crises: EMP > 2 desvios padrão
threshold = df["emp"].mean() + 2 * df["emp"].std()
df["crise"] = df["emp"] > threshold

print(f"Períodos de crise cambial (EMP > {threshold:.1f}):")
```

```

crises = df[df["crise"]].index
for data in crises:
    print(f" {data.date()}")

# Gráfico
fig, ax = plt.subplots(figsize=(12, 5))
ax.plot(df.index, df["emp"], color="steelblue", linewidth=1)
ax.axhline(threshold, color="red", linestyle="--", label=f"Limiar crise
({threshold:.1f})")
ax.fill_between(df.index, threshold, df["emp"].max(),
                where=df["crise"], color="red", alpha=0.3, label="Crise")
ax.legend()
ax.set_title("Índice de Pressão Cambial - Brasil")
ax.set_ylabel("EMP (desvios padrão)")
ax.grid(True, alpha=0.3)
fig.tight_layout()
fig.savefig("crise_cambial.png", dpi=150)

```

Desafio

Estenda o índice EMP para incluir o diferencial de juros (SELIC menos Fed Funds) como terceiro componente, seguindo a formulação estendida de Eichengreen, Rose e Wyplosz (1996). O número de crises identificadas muda? Compare também os resultados usando $k = 1, 5$ e $k = 3$ e discuta o trade-off entre falsos positivos e crises não detectadas.

Projeto 7 — TCC Estrutura Completa

Estrutura de um TCC em economia com Python:

```

meu_tcc/
├── dados/                # Dados brutos (nunca modificados)
│   ├── bcb/             # Baixados do BCB
│   ├── ipea/            # Baixados do Ipeadata
│   └── externos/        # Banco Mundial, FMI
├── scripts/             # Código
│   ├── 01_baixar_dados.py
│   ├── 02_limpeza.py
│   ├── 03_analise_descritiva.py
│   ├── 04_modelos.py
│   └── 05_graficos.py
├── output/              # Resultados
│   ├── tabelas/
│   ├── graficos/
│   └── relatorio/
├── environment.yml      # Ambiente replicável
└── README.md

```

Fundamentação teórica

Um TCC (ou artigo de pesquisa) em economia aplicada normalmente evolui de uma pergunta descritiva para uma tentativa de identificação causal, e a estrutura de pastas acima reflete diretamente essa lógica: dados brutos nunca são modificados (permitindo auditoria — qualquer revisor deveria conseguir refazer sua análise do zero a partir do dado original), scripts são numerados na ordem de execução, e resultados são exportados para tabelas e gráficos versionáveis.

Por que dados em painel, e não corte transversal ou série temporal isolada. O script-modelo estima tanto um OLS simples quanto um modelo de efeitos fixos (`PanelOLS.from_formula(... +`

EntityEffects)), o que introduz uma questão central de dados em painel: como controlar por características não observadas de cada unidade (país, estado, firma) que são constantes no tempo mas afetam tanto a variável dependente quanto os regressores. No modelo geral de painel,

$$y_{it} = \beta' X_{it} + \alpha_i + \varepsilon_{it}$$

α_i é o **efeito individual não observado** (por exemplo, qualidade institucional de um país, constante ano a ano). Se α_i está correlacionado com algum regressor em X_{it} — o caso mais comum e mais preocupante em economia —, estimar por OLS agrupado (*pooled OLS*, ignorando a estrutura de painel) produz **viés de variável omitida**.

Efeitos fixos: eliminando α_i por transformação. O estimador de efeitos fixos resolve isso subtraindo a média de cada unidade ao longo do tempo (transformação *within*):

$$y_{it} - \bar{y}_i = \beta'(X_{it} - \bar{X}_i) + (\varepsilon_{it} - \bar{\varepsilon}_i)$$

Como α_i é constante no tempo, ele desaparece na subtração ($\bar{\alpha}_i = \alpha_i$) — o preço é que qualquer variável igualmente constante no tempo dentro de cada unidade (ex: um país que não muda de continente) também é eliminada e não pode ser estimada.

Efeitos aleatórios e o teste de Hausman. O estimador de efeitos aleatórios trata α_i como parte do erro (não o remove por transformação), o que é mais eficiente — mas só é não viesado sob a hipótese, frequentemente implausível em economia, de que α_i não é correlacionado com os regressores. O teste de especificação padrão para decidir entre os dois é o **teste de Hausman** (Hausman, 1978):

$$H = (\hat{\beta}_{FE} - \hat{\beta}_{RE})' [\text{Var}(\hat{\beta}_{FE}) - \text{Var}(\hat{\beta}_{RE})]^{-1} (\hat{\beta}_{FE} - \hat{\beta}_{RE}) \sim \chi_k^2$$

Sob H_0 (efeitos aleatórios consistente), os dois estimadores deveriam ser parecidos; uma diferença estatisticamente grande rejeita H_0 e recomenda efeitos fixos, apesar do custo de eficiência.

Erros-padrão clusterizados. Mesmo depois de escolher entre efeitos fixos e aleatórios, um problema separado costuma passar despercebido em TCCs: os erros ε_{it} de uma mesma unidade i ao longo do tempo tendem a ser correlacionados entre si (autocorrelação serial dentro de cada país/firma), o que viola a hipótese de erros independentes do OLS clássico e faz os erros-padrão “de fábrica” subestimarem a incerteza real — inflando artificialmente a significância estatística. A correção padrão é usar erros-padrão **clusterizados por entidade** (`.fit(cov_type="clustered", cluster_entity=True)` no `linearmodels`), que permitem correlação arbitrária dentro de cada cluster (cada país, por exemplo) sem exigir que se conheça a estrutura exata dessa correlação. Reportar um modelo de efeitos fixos sem esse ajuste é um dos erros metodológicos mais comuns — e mais fáceis de corrigir — em TCCs com dados em painel.

Correlação ainda não é causalidade. Mesmo com efeitos fixos bem especificados, o modelo só produz estimativas causais válidas se não houver viés de variável omitida **variante no tempo**, nem causalidade reversa (educação causa crescimento, ou países que já crescem mais investem mais em educação?). Um TCC rigoroso discute essas ameaças à identificação explicitamente na seção de limitações — não como formalidade, mas porque é exatamente o que um orientador ou parecerista vai procurar.

Robustez como parte do método, não como apêndice. Um resultado empírico único, de uma única especificação, convence pouco — inclusive porque a escolha de variáveis de controle, amostra e forma funcional envolve graus de liberdade que o próprio pesquisador tem, o que a literatura recente chama de “jardim de caminhos que se bifurcam” (*garden of forking paths*, Gelman & Loken, 2013) ou, na versão mais conhecida em economia, os “muitos universos” de especificações possíveis (*specification curve*, Simonsohn et al., 2020). A prática recomendada — e o que um bom TCC deveria

reportar, mesmo que resumidamente — é testar se o resultado central se mantém sob especificações alternativas razoáveis: outro conjunto de controles, outra janela temporal, outra forma funcional (níveis vs. logs), erros-padrão clusterizados de formas diferentes. Se o coeficiente de interesse muda de sinal ou perde significância nessas variações, isso é informação tão importante quanto o resultado da especificação preferida.

Antes de rodar

- Quais variáveis do seu tema de TCC são plausivelmente correlacionadas com um efeito não observado de país/firma/indivíduo (α_i)? Isso te faz preferir efeitos fixos a efeitos aleatórios, ou o contrário?
- Se o coeficiente de uma variável de interesse mudar substancialmente entre o OLS agrupado e o modelo de efeitos fixos, o que isso sugere sobre a importância do viés de variável omitida no seu caso?

Template de script de TCC

```
"""
TCC: [TÍTULO]
Autor: [SEU NOME]
Script: 04_modelos.py
Descrição: Estima modelos econométricos
"""

import pandas as pd
import numpy as np
import statsmodels.api as sm
from linearmodels.panel import PanelOLS
import warnings
warnings.filterwarnings("ignore")

# Configuração
np.random.seed(42)
SAVE_TABLES = True

# 1. CARREGAR DADOS
df = pd.read_csv("dados/painel_paises.csv", decimal=",")
print(f"Dados carregados: {df.shape[0]} observações, {df.shape[1]} variáveis")

# 2. ESTATÍSTICAS DESCRITIVAS
desc = df.describe().round(3)
if SAVE_TABLES:
    desc.to_csv("output/tabelas/descritivas.csv", decimal=",")
print("\nEstatísticas descritivas salvas")

# 3. MODELO BASE
X = sm.add_constant(df[["inflacao", "educacao", "investimento"]])
y = df["crescimento_pib"]

modelo_base = sm.OLS(y, X).fit()
print("\nMODELO BASE (OLS)")
print("=" * 50)
print(modelo_base.summary())

# 4. MODELO COM EFEITOS FIXOS
df_panel = df.set_index(["pais", "ano"])
modelo_fe = PanelOLS.from_formula(
```

```

    "crescimento_pib ~ inflacao + educacao + investimento + EntityEffects",
    data=df_panel
).fit()

print("\nMODELO EFEITOS FIXOS")
print("=" * 50)
print(modelo_fe)

# 5. SALVAR RESULTADOS
# Coeficientes em CSV
coefs = pd.DataFrame({
    "variavel": modelo_fe.params.index,
    "coeficiente": modelo_fe.params.values,
    "p_valor": modelo_fe.pvalues.values,
    "erro_padrao": modelo_fe.std_errors.values
})
coefs.to_csv("output/tabelas/resultados_fe.csv", index=False, decimal=",")
print("\nResultados salvos em output/tabelas/")

print("\n✅ Modelos estimados com sucesso!")

```

Desafio

Adicione ao template um teste de Hausman comparando o modelo de efeitos fixos com um modelo de efeitos aleatórios (RandomEffects do linearmodels) para os mesmos dados. Com base no resultado, justifique por escrito (como faria na seção de metodologia de um TCC) qual dos dois modelos você reportaria como principal.

Checklist para seu TCC

- ☐ Dados brutos salvos em dados/ (nunca modificá-los)
 - ☐ Scripts numerados na ordem de execução
 - ☐ Mesma seed (np.random.seed(42)) em todos os scripts
 - ☐ Tabelas exportadas para CSV com decimal=", "
 - ☐ Gráficos em PNG 300dpi
 - ☐ Ambiente replicável (environment.yml ou requirements.txt)
 - ☐ README explicando como reproduzir
-

Projeto 8 — Desafios Adicionais para Executar

Diferente dos Projetos 1 a 7, esta seção não é um projeto completo — é uma lista de exercícios pontuais, mais curtos, cada um reforçando um conceito específico das Apostilas 1 a 4, aplicado a dados reais. **Nenhuma solução é apresentada aqui:** o objetivo é que você escreva o código do zero, execute, confira o resultado contra sua própria expectativa (formada na seção “Antes de rodar” de cada projeto anterior) e só então avance para o próximo. Se travar, revise o capítulo indicado entre parênteses antes de espiar qualquer solução de terceiros.

1. **Fisher exato vs. aproximado em série longa.** Baixe a SELIC e o IPCA acumulado em 12 meses via `bcb.sgs` desde 2000. Calcule o juro real pela aproximação simples (`selic - ipca`) e pela fórmula exata de Fisher (Apostila 1, Capítulo 5) para toda a série. Plote a diferença entre as duas ao longo do tempo — em quais períodos (alta ou baixa inflação) a diferença é maior?
2. **Limpeza de dado “sujo”.** Baixe uma tabela do IPEADATA ou do SIDRA/IBGE em formato bruto (números brasileiros com . de milhar e , decimal). Escreva uma função que limpe a coluna

de valores e converta para `float`, reaproveitando o raciocínio “limpar → ajustar → converter” da Apostila 1 (Capítulo 4).

3. **Aliasing em um pipeline real.** Carregue uma série do BCB em um `DataFrame`, crie uma “cópia” sem usar `.copy()` e aplique uma transformação (ex: preencher valores ausentes). Mostre que a série original também foi alterada, e depois corrija usando `.copy()` (Apostila 1, Capítulo 7; Apostila 2).
4. **Outliers em série real.** Usando a série de câmbio diário (BCB, código 1) desde 1999 (inclui o regime de bandas cambiais pré-1999 se você estender o período), identifique observações que sejam outliers pelo critério de desvio-padrão (ex: variação diária acima de 3 desvios-padrão da série) e liste as datas — elas coincidem com eventos macroeconômicos conhecidos?
5. **Estatísticas descritivas comparadas.** Baixe o IPCA mensal para dois subperíodos de sua escolha (ex: regime de metas de inflação em dois governos diferentes) e compare média, desvio-padrão e assimetria (`.skew()`) entre eles. A volatilidade da inflação foi diferente entre os dois períodos?
6. **Regressão simples com dado real (não simulado).** Refaça a regressão do Projeto 2 (β -convergência) substituindo os dados simulados por dados reais do WDI para pelo menos 15 países de sua escolha. Reporte se o sinal e a significância do β mudam em relação ao exemplo simulado do projeto.
7. **Teste de estacionariedade em três séries diferentes.** Aplique o teste ADF (Apostila 4) a três séries do BCB com características distintas: uma taxa de juros (deveria ser mais persistente), uma variação percentual (deveria ser mais estacionária) e um índice de preços em nível (deveria ter raiz unitária clara). Compare os p-valores e explique o padrão encontrado.
8. **Curva de Phillips com dados atualizados.** Reestime a Curva de Phillips (Apostila 4, Capítulo 4) usando os dados mais recentes disponíveis de desemprego (PNAD Contínua) e inflação. O trade-off (inclinação negativa) se mantém na amostra mais recente?
9. **Visualização de múltiplas séries com eixos duplos.** Usando a técnica de eixo duplo (`ax.twinx()`, Apostila 3), plote SELIC e câmbio na mesma figura com escalas diferentes. Adicione uma linha vertical (`axvline`) marcando o início de um ciclo de aperto monetário à sua escolha.
10. **Painel simples com efeitos fixos em dados reais.** Monte um pequeno painel (ex: PIB per capita e escolaridade de 10 estados brasileiros ao longo de 5 anos, via IBGE/SIDRA) e estime um modelo de efeitos fixos por entidade (Projeto 7). Compare com a versão sem efeitos fixos (pooled OLS) — o coeficiente de interesse muda de sinal ou magnitude?
11. **Índice de pressão cambial para outro país.** Adapte o índice EMP do Projeto 6 para outro país emergente (ex: Argentina, Turquia) usando série de câmbio e reservas de fontes públicas (FMI IFS, banco central local). Os períodos de crise identificados coincidem com eventos históricos conhecidos desse país?
12. **Regra de Taylor com suavização.** A partir do Projeto 5, estime a regra de Taylor **com** o termo de suavização (i_{t-1} como regressor) e calcule o ρ implícito de suavização. Compare o R^2 ajustado com e sem esse termo.
13. **Função pura para relatório reprodutível.** Escreva uma função `gerar_relatorio(df, indicadores)` que receba um `DataFrame` e uma lista de nomes de colunas e devolva um dicionário com média, mínimo, máximo e variação percentual do último valor de cada indicador

— sem modificar o DataFrame original (Apostila 1, Capítulo 11, função pura vs. impura). Teste que rodar a função duas vezes seguidas produz exatamente o mesmo resultado.

14. **Índice de Miséria brasileiro.** Usando IPCA acumulado 12 meses e taxa de desocupação (PNAD Contínua, ambos via BCB), construa a série do Índice de Miséria (Projeto 1) desde 2012 e identifique o mês em que ele atingiu seu valor máximo e mínimo na amostra. O que estava acontecendo na economia brasileira nesses dois momentos?
15. **ACF e PACF na prática.** Para a série de IPCA mensal, plote a ACF e a PACF (`statsmodels.graphics.tsaplots.plot_acf` e `plot_pacf`, Projeto 4) até 24 defasagens. Com base no padrão visual (corte abrupto vs. decaimento geométrico), proponha uma ordem (p, q) para um ARIMA e compare com a ordem usada no script do Projeto 4.
16. **AIC/BIC para seleção de modelo.** Ainda sobre a série de IPCA, estime três ARIMAs com ordens diferentes (por exemplo, $(1, 1, 1)$, $(2, 1, 1)$, $(1, 1, 2)$) e compare o AIC e o BIC de cada um. O modelo com menor AIC é o mesmo com menor BIC? Se não for, qual critério você prefere seguir, e por quê (pesquise a diferença de penalização entre os dois critérios)?
17. **Testando o Princípio de Taylor em outro país.** Repita a regressão do Projeto 5 usando dados de outro banco central com séries públicas (ex: Fed dos EUA, via FRED) e verifique se o coeficiente estimado para a inflação é maior que 1, como o Princípio de Taylor recomenda para uma política monetária estabilizadora.

Nenhuma dessas soluções está incluída neste documento — a ideia é que você as implemente, rode com dados reais, e compare o resultado com a intuição que você registrou antes de escrever a primeira linha de código.

Notas e referências bibliográficas

As seções de fundamentação teórica desta apostila se apoiam em resultados e conceitos consolidados na literatura de macroeconomia, crescimento e econometria. Para quem quiser aprofundar qualquer um dos sete projetos, os textos originais (ou os manuais que os resumem) são:

- **Projeto 1 (Fisher, Okun):** Fisher, I. (1930). *The Theory of Interest*. Okun, A. (1962). “Potential GNP: Its Measurement and Significance”.
- **Projeto 2 (Solow, convergência):** Solow, R. (1956). “A Contribution to the Theory of Economic Growth”. *QJE*. Barro, R. & Sala-i-Martin, X. (1992). “Convergence”. *Journal of Political Economy*. Barro & Sala-i-Martin também têm um livro-texto de referência, *Economic Growth* (MIT Press), com um capítulo inteiro dedicado a β - e σ -convergência.
- **Projeto 3 (Kuznets Ambiental):** Kuznets, S. (1955). “Economic Growth and Income Inequality”. *American Economic Review*. Grossman, G. & Krueger, A. (1991, 1995). “Environmental Impacts of a North American Free Trade Agreement” e “Economic Growth and the Environment”. Panayotou, T. (2000), levantamento crítico da EKC para a OIT.
- **Projeto 4 (Box-Jenkins, SARIMA):** Box, G. & Jenkins, G. (1970). *Time Series Analysis: Forecasting and Control* — a referência original da metodologia. Dickey, D. & Fuller, W. (1979). “Distribution of the Estimators for Autoregressive Time Series with a Unit Root”. *JASA*.
- **Projeto 5 (Regra de Taylor, filtro HP):** Taylor, J. (1993). “Discretion versus Policy Rules in Practice”. *Carnegie-Rochester Conference Series*. Hodrick, R. & Prescott, E. (1997). “Postwar U.S. Business Cycles: An Empirical Investigation”. Orphanides, A. (2001). “Monetary Policy Rules Based on Real-Time Data”.
- **Projeto 6 (Crise cambial, EMP):** Girton, L. & Roper, D. (1977). “A Monetary Model of Exchange Market Pressure”. Eichengreen, B., Rose, A. & Wyplosz, C. (1996). “Contagious Currency Crises”.

Krugman, P. (1979). “A Model of Balance-of-Payments Crises”; (1999) “Balance Sheets, the Transfer Problem, and Financial Crises”. Obstfeld, M. (1994, 1996) sobre modelos de segunda geração e equilíbrios múltiplos.

- **Projeto 7 (Painel, Hausman):** Hausman, J. (1978). “Specification Tests in Econometrics”. *Econometrica*. Wooldridge, J. (edição mais recente). *Econometric Analysis of Cross Section and Panel Data* — referência-padrão de pós-graduação para efeitos fixos, aleatórios e erros clusterizados.

Nenhuma dessas referências é necessária para rodar os scripts — mas qualquer um dos Desafios ou dos exercícios do Projeto 8 que você decidir aprofundar em um artigo, TCC ou dissertação deveria, em algum momento, remeter a esses textos originais, não apenas a este material introdutório.

Conclusão

Você tem agora 7 projetos completos, mais uma lista de exercícios pontuais adicionais (Projeto 8), cobrindo tanto a técnica quanto a teoria por trás dela:

Projeto	Técnicas	Teoria econômica central
1. Dashboard Macro	API BCB, pandas, matplotlib	Equação de Fisher, transmissão de política monetária
2. β -Convergência	Regressão, scatter	Modelo de Solow-Swan, β - e σ -convergência
3. Curva de Kuznets	Regressão quadrática	Efeitos escala/composição/técnica, EKC
4. Previsão IPCA	SARIMA, séries temporais	Box-Jenkins, raiz unitária, teste ADF
5. Regra de Taylor	Econometria, filtro HP	Princípio de Taylor, suavização de juros
6. Crise Cambial	Análise de indicadores	Índice EMP, modelos de crise cambial (1 ^a /2 ^a /3 ^a geração)
7. TCC	Estrutura completa	Dados em painel, efeitos fixos vs. aleatórios, teste de Hausman
8. Desafios adicionais	13 exercícios curtos	Revisão aplicada das Apostilas 1–4

Um padrão comum aos sete projetos vale destacar: em nenhum deles o script sozinho “prova” a teoria. Um coeficiente com o sinal esperado é **consistente** com a hipótese testada, não uma prova definitiva — outras variáveis omitidas, escolhas de amostra e forma funcional sempre podem estar por trás do resultado. É por isso que cada seção “Antes de rodar” pede que você registre uma expectativa antes de ver o resultado: o valor de um exercício empírico está tanto em confirmar quanto em **surpreender** sua intuição teórica, e só dá para perceber a surpresa se a expectativa foi anotada com antecedência.

Pegue qualquer um dos projetos, adapte com seus próprios dados e sua própria pergunta de pesquisa, resolva os desafios e os exercícios do Projeto 8 sem consultar solução pronta — e está pronto para virar portfólio, TCC ou relatório de research.