

Python para Economia — Livro- Texto Completo

Autor: Gerado por IA — Estude, pratique, erre, aprenda.

Parte I — Fundamentos de Python

“A melhor maneira de aprender programação é programar. A melhor maneira de aprender economia é programar modelos econômicos.”

Capítulo 1 — Introdução

1.1 Por que Python?

Python se tornou a linguagem padrão em economia por razões objetivas:

1. **Curva de aprendizado suave** — sua sintaxe se aproxima do inglês/português
2. **Ecossistema maduro** — pandas (dados tabulares), numpy (matemática), statsmodels (econometria), matplotlib (gráficos)
3. **Reprodutibilidade** — scripts substituem comandos manuais no Excel/Stata
4. **Gratuito e aberto** — ao contrário de Stata, SAS, EViews

Instituições que usam Python: - Banco Central do Brasil - FMI (Fundo Monetário Internacional) - Banco Mundial - MIT, Harvard, Chicago (cursos de economia) - Quase todas as fintechs e bancos

1.2 Como este livro está organizado

Cada capítulo segue a mesma estrutura:

1. **Conceito** — explicação teórica
2. **Aplicação econômica** — exemplo real
3. **Código** — implementação completa
4. **Exercícios** — para fixação (com soluções no apêndice)

1.3 Como usar este livro

Você precisa de:

1. **Python 3.11+** instalado (já temos no sistema)
2. **Ambiente virtual** ativado (`source ~/economia/.venv/bin/activate`)
3. **Editor de texto** (Cursor AI / VS Code)
4. **Um terminal aberto** para executar os exemplos

Cada bloco de código neste livro foi testado e executa sem erros. Copie, cole, modifique.

Capítulo 2 — Variáveis, Tipos e Operadores

2.1 O que é uma variável?

Uma variável é um nome que armazena um valor na memória do computador. Pense nela como uma caixa com uma etiqueta.

```
pib_brasil_2025 = 2.2 # a caixa se chama "pib_brasil_2025" e contém 2.2
```

Quando você escreve `pib_brasil_2025`, o computador substitui pelo valor `2.2`.

2.2 Tipos de dados fundamentais

Python reconhece quatro tipos básicos automaticamente (tipagem dinâmica).

Inteiros (int)

Números sem casa decimal:

```
ano = 2026
populacao = 214000000
renda_per_capita = 45000
republica_anos = 136 # desde 1889
```

Operações com inteiros produzem inteiros ou floats:

```
print(type(ano))          # <class 'int'>
print(10 / 3)             # 3.333... (divisão sempre retorna float)
```

```
print(10 // 3)      # 3 (divisão inteira)
print(10 % 3)       # 1 (resto da divisão)
```

Ponto flutuante (float)

Números decimais:

```
ipca_mensal = 0.16
taxa_selic = 14.75
cambio_usd = 5.45
elasticidade = -0.42
```

Cuidado com precisão:

```
print(0.1 + 0.2)      # 0.30000000000000004 (erro de ponto flutuante)
print(round(0.1 + 0.2, 2)) # 0.3 (sempre arredonde para exibição)
```

Strings (str)

Texto. Sempre entre aspas (simples ou duplas):

```
pais = "Brasil"
sigla = 'BR'
frase = "O PIB cresceu 3.2% em 2025"
vazio = ""
multilinha = """Este é um texto
que ocupa várias linhas"""
```

Caracteres especiais:

```
print("Linha 1\nLinha 2")  # \n = nova linha
print("Coluna1\tColuna2")  # \t = tabulação
```

Booleanos (bool)

Verdadeiro ou falso. Usado em decisões:

```
em_recessao = False
crescendo = True
```

2.3 Operadores aritméticos

```
a = 1000    # principal (R$)
b = 0.01    # taxa de juros (1%)
c = 12       # meses

# Operações básicas
soma = a + a * b * c          # 1120
subtracao = a - 50           # 950
multiplicacao = a * b         # 10
divisao = a / b               # 100000

# Juros compostos
montante = a * (1 + b) ** c   # 1126.83 (mais que 1120 dos juros simples)

# Potenciação
print(10 ** 2)               # 100
print(10 ** 3)               # 1000
print(10 ** -1)              # 0.1

# Ordem das operações (parênteses primeiro)
x = 2 + 3 * 4                 # 14
y = (2 + 3) * 4               # 20
```

2.4 Operadores de comparação

Sempre retornam bool:

```
5 == 5      # True (igual)
5 != 3      # True (diferente)
5 > 3       # True
5 < 3       # False
5 >= 5      # True
5 <= 4      # False
```

Aplicação econômica:

```
pib = -1.5
inflacao = 5.2
desemprego = 11.3

print(pib < 0)                # True (PIB negativo)
print(inflacao > 4.5)         # True
print(desemprego >= 10)       # True
```

2.5 Operadores lógicos

Combinam condições:

```
# AND – ambas verdadeiras
True and True      # True
True and False     # False

# OR – pelo menos uma verdadeira
True or False      # True
False or False     # False

# NOT – inverte
not True           # False
```

Aplicação: detectar estagflação:

```
pib = -0.5
inflacao = 7.2

estagflacao = pib < 0 and inflacao > 5
print(estagflacao) # True

# Ou recessão ou inflação alta
alerta = pib < 0 or inflacao > 8
```

2.6 Conversão entre tipos

```
# str -> int
int("2026")          # 2026

# int -> str
str(2026)            # "2026"

# str -> float
float("5.45")        # 5.45

# float -> int (trunca!)
int(5.99)            # 5 (cuidado!)

# número -> bool
bool(0)              # False
bool(1)              # True
bool(-1)             # True
bool(0.0)            # False
```

2.7 F-strings (formatação)

Essencial para exibir resultados de forma clara:

```
pais = "Brasil"
pib = 2.2
ano = 2025
```

```

# Básico
print(f"{pais} cresceu {pib}% em {ano}")

# Controlar casas decimais
pi = 3.14159265
print(f"{pi:.2f}")    # 3.14
print(f"{pi:.4f}")    # 3.1416

# Formatando porcentagem
print(f"{pib:.1f}%")  # "2.2%"

# Alinhamento
print(f"'Direita':>10}") # "      Direita"
print(f"'Esquerda':<10}") # "Esquerda  "
print(f"'Centro':^10}")  # "  Centro  "

# Números grandes
pop = 214000000
print(f"{pop:,}")        # 214,000,000
print(f"{pop:_}")        # 214_000_000

```

2.8 Aplicação econômica completa

```

# Cenário: investimento de R$ 10.000
valor_inicial = 10000
taxa_anual = 0.08 # 8% ao ano
anos = 10

# Cálculo de juros compostos
valor_final = valor_inicial * (1 + taxa_anual) ** anos
rendimento = valor_final - valor_inicial

print(f"Investimento inicial: R$ {valor_inicial:,.2f}")
print(f"Taxa: {taxa_anual * 100:.1f}% ao ano")
print(f"Período: {anos} anos")
print(f"Valor final: R$ {valor_final:,.2f}")
print(f"Rendimento: R$ {rendimento:,.2f}")
print(f"Multiplicador: {(1 + taxa_anual) ** anos:.2f}x")

```

Saída:

```

Investimento inicial: R$ 10,000.00
Taxa: 8.0% ao ano
Período: 10 anos
Valor final: R$ 21,589.25
Rendimento: R$ 11,589.25
Multiplicador: 2.16x

```

Exercícios do Capítulo 2

1. Calcule o montante de R\$ 5.000 a 1,5% ao mês por 24 meses
2. Converta US\$ 1.000 em reais (câmbio = R\$ 5,45) e exiba com duas casas decimais

3. Verifique se as seguintes condições são True/False:

- `10 > 5 and 3 < 2`
- `7 == 7 or 4 != 4`
- `not (5 <= 3)`

4. Dada inflação de 4,8% e meta de 3,5%, crie uma variável bool `meta_descumprida`

Capítulo 3 — Estruturas de Dados

3.1 Listas

Lista é uma coleção ordenada e mutável de elementos.

Criando listas

```
# Lista de números
inflacoes = [0.50, 0.70, 0.88, 0.67, 0.58, 0.16]

# Lista de strings
paises = ["Brasil", "Argentina", "Chile", "Peru"]

# Lista mista (evite – prejudica a clareza)
mista = [1, "texto", True, 3.14]

# Lista vazia
vazia = []
vazia = list()
```

Acessando elementos

O índice começa em **zero**:

```
inflacoes[0]    # 0.50 (primeiro elemento)
inflacoes[1]    # 0.70 (segundo elemento)
inflacoes[5]    # 0.16 (sexto elemento)
inflacoes[-1]   # 0.16 (último elemento)
inflacoes[-2]   # 0.58 (penúltimo)

# Erro comum
inflacoes[10]   # IndexError: list index out of range
```

Fatiamento (slicing)

Sintaxe: `lista[inicio:fim:passo]`

```
numeros = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]

numeros[0:3]      # [0, 1, 2] (índices 0, 1, 2 – o 3 não entra)
numeros[:3]       # [0, 1, 2] (mesma coisa, início implícito)
numeros[3:]       # [3, 4, 5, 6, 7, 8, 9]
numeros[2:7]      # [2, 3, 4, 5, 6]
numeros[::2]      # [0, 2, 4, 6, 8]
numeros[1::2]     # [1, 3, 5, 7, 9]
numeros[::-1]     # [9, 8, 7, 6, 5, 4, 3, 2, 1, 0] (inverte)
numeros[-3:]      # [7, 8, 9] (últimos 3)
numeros[:-3]      # [0, 1, 2, 3, 4, 5, 6]
```

Métodos de lista

```
dados = [1, 2, 3]

dados.append(4)      # [1, 2, 3, 4] (adiciona ao final)
dados.insert(0, 0)   # [0, 1, 2, 3, 4] (insere na posição)
dados.extend([5, 6]) # [0, 1, 2, 3, 4, 5, 6]
dados.pop()          # remove e retorna o último (6)
dados.pop(0)         # remove e retorna o índice 0 (0)
dados.remove(3)       # remove o valor 3
dados.sort()         # ordena crescente
dados.sort(reverse=True) # ordena decrescente
dados.reverse()      # inverte a ordem
```

Funções nativas para listas

```
numeros = [3, 7, 1, 9, 4, 6]

len(numeros)        # 6 (tamanho)
sum(numeros)         # 30
max(numeros)         # 9
min(numeros)         # 1
sorted(numeros)      # [1, 3, 4, 6, 7, 9]
sorted(numeros, reverse=True) # [9, 7, 6, 4, 3, 1]
any([False, True])   # True (pelo menos um True)
all([True, True])    # True (todos True)
```

Aplicação econômica

```
# Taxas de crescimento do PIB de 5 países
pibs = [2.2, -1.8, 3.1, 2.8, -0.5]
paises = ["Brasil", "Argentina", "Chile", "Colômbia", "Uruguai"]
```

```
print(f"PIB médio: {sum(pibs) / len(pibs):.1f}%")
print(f"Maior PIB: {max(pibs)}% ({países[pibs.index(max(pibs))])}")
print(f"Menor PIB: {min(pibs)}% ({países[pibs.index(min(pibs))])}")
print(f"Países em recessão: {sum(1 for p in pibs if p < 0)}")
```

3.2 Tuplas

Tupla é como uma lista, mas **imutável** (não pode ser alterada depois de criada).

```
# Criando tuplas
coordenadas = (-23.5, -46.6) # latitude, longitude de SP
trimestre = (1, 2, 3)        # meses do primeiro trimestre

# Acesso igual à lista
coordenadas[0] # -23.5

# Diferença crucial:
coordenadas[0] = -22 # TypeError: 'tuple' object does not support item assignment

# Usos comuns:
# 1. Funções que retornam múltiplos valores (internamente são tuplas)
# 2. Dados que não devem ser modificados
# 3. Chaves de dicionário (listas não podem)
```

3.3 Dicionários

Armazenam pares **chave: valor**. É a estrutura mais importante depois da lista.

Criando dicionários

```
# Dicionário de indicadores
indicadores = {
    "pais": "Brasil",
    "pib": 2.2,
    "inflacao": 4.5,
    "selic": 14.75,
    "desemprego": 11.3
}

# Outra forma
pibs = dict(Brasil=2.2, Argentina=-1.8, Chile=3.1)
```

Acessando valores

```
indicadores["pais"] # "Brasil"
indicadores.get("pais") # "Brasil" (seguro)
indicadores.get("cambio", 0.0) # 0.0 (valor padrão se não existir)
```

```
# Erro comum
indicadores["cambio"]      # KeyError: 'cambio'
```

Adicionar e modificar

```
indicadores["cambio"] = 5.45      # adiciona
indicadores["pib"] = 2.5          # modifica

# Atualizar múltiplos de uma vez
indicadores.update({"pib": 2.8, "inflacao": 4.8})
```

Métodos de dicionário

```
indicadores.keys()      # dict_keys(['pais', 'pib', ...])
indicadores.values()    # dict_values(['Brasil', 2.2, ...])
indicadores.items()     # dict_items([('pais', 'Brasil'), ...])

list(indicadores.keys()) # converter para lista

# Verificar se chave existe
"pib" in indicadores    # True
"cambio" in indicadores # False if not added

# Remover
removido = indicadores.pop("cambio") # remove e retorna o valor
del indicadores["cambio"] # remove sem retornar

# Tamanho
len(indicadores) # número de pares
```

Aplicação econômica

```
# Dicionário aninhado (dados de múltiplos países)
paises = {
    "Brasil": {"pib": 2.2, "inflacao": 4.5, "populacao": 214},
    "Chile": {"pib": 3.1, "inflacao": 3.8, "populacao": 19},
    "Argentina": {"pib": -1.8, "inflacao": 98.0, "populacao": 46},
}

for pais, dados in paises.items():
    print(f"{pais}: PIB {dados['pib']}%, Inflação {dados['inflacao']}%")
```

3.4 Conjuntos (set)

Coleção não ordenada de elementos únicos:

```
# Remover duplicatas
paises_visita = ["Brasil", "Chile", "Brasil", "Peru", "Chile"]
```

```
unicos = set(paises_visita) # {"Brasil", "Chile", "Peru"}

# Operações de conjunto
conjunto_a = {1, 2, 3, 4}
conjunto_b = {3, 4, 5, 6}

conjunto_a & conjunto_b # {3, 4} (interseção)
conjunto_a | conjunto_b # {1, 2, 3, 4, 5, 6} (união)
conjunto_a - conjunto_b # {1, 2} (diferença)
```

Exercícios do Capítulo 3

1. Dada a lista `pib = [2.2, -1.8, 3.1, 2.8, -0.5]`, calcule:
 - Quantos países tiveram PIB positivo
 - O PIB médio apenas dos positivos
2. Crie um dicionário com 3 indicadores de 2 países. Calcule a diferença de inflação entre eles.
3. Use fatiamento para extrair:
 - Os 3 primeiros meses de `ipca = [0.5, 0.7, 0.88, 0.67, 0.58, 0.16]`
 - Os 3 últimos
 - A lista invertida
4. Dado o dicionário `moedas = {"USD": 5.45, "EUR": 5.95, "GBP": 6.90, "ARS": 0.006}`:
 - Qual moeda tem a maior taxa?
 - Quantas moedas estão abaixo de R\$ 1,00?
 - Adicione "JPY": 0.036

Capítulo 4 — Controle de Fluxo

4.1 Condicionais (if/elif/else)

Permitem que o programa tome decisões.

Estrutura básica

```
if condicao:
    # bloco executado se condicao for True
    pass
```

```

elif outra_condicao:
    # bloco executado se a primeira for False e esta for True
    pass
else:
    # bloco executado se todas as anteriores forem False
    pass

```

Exemplos econômicos

```

# Classificação de inflação
inflacao = 7.2

if inflacao > 10:
    print("Hiperinflação")
elif inflacao > 6:
    print("Inflação alta")
elif inflacao > 3:
    print("Inflação moderada")
elif inflacao > 0:
    print("Inflação controlada")
else:
    print("Deflação")

# Aninhamento
pib = -0.8
desemprego = 12.5

if pib < 0:
    if desemprego > 10:
        print("Recessão com alto desemprego")
    else:
        print("Recessão")
elif pib > 0:
    print("Crescimento")

```

Operador ternário

```

# Forma compacta de if/else
status = "Crescendo" if pib > 0 else "Recessão"

# Equivalente a:
if pib > 0:
    status = "Crescendo"
else:
    status = "Recessão"

```

Match/case (Python 3.10+)

```

# Similar ao switch de outras linguagens
codigo_pais = "BR"

```

```
match codigo_pais:
    case "BR":
        nome = "Brasil"
    case "AR":
        nome = "Argentina"
    case "CL":
        nome = "Chile"
    case _:
        nome = "Outro"
```

4.2 Loop for

Percorre elementos de uma sequência.

For com listas

```
inflacoes = [0.5, 0.7, 0.88, 0.67]

for valor in inflacoes:
    print(f"IPCA: {valor}%")

# Com enumerate (índice + valor)
for i, valor in enumerate(inflacoes):
    print(f"Mês {i + 1}: {valor}%")
```

For com dicionários

```
pibs = {"Brasil": 2.2, "Chile": 3.1, "Peru": 2.5}

# Apenas chaves
for pais in pibs:
    print(pais)

# Chaves e valores
for pais, valor in pibs.items():
    print(f"{pais}: {valor}%")
```

For com range()

```
# range(5) → 0, 1, 2, 3, 4
for i in range(5):
    print(i)

# range(inicio, fim)
for mes in range(1, 13):
    print(f"Mês {mes}")

# range(inicio, fim, passo)
```

```
for ano in range(2000, 2026, 5):
    print(f"Ano {ano}")
```

Aplicação: juros compostos mês a mês

```
saldo = 1000
taxa = 0.01 # 1% ao mês

print("Mês Saldo")
print("=" * 12)
for mes in range(1, 13):
    saldo *= (1 + taxa)
    print(f"{mes:3d} R$ {saldo:>8.2f}")
```

4.3 Loop while

Repete enquanto a condição for verdadeira.

```
# Mesmo exemplo com while
saldo = 1000
taxa = 0.01
mes = 1

while mes <= 12:
    saldo *= (1 + taxa)
    print(f"Mês {mes}: R$ {saldo:.2f}")
    mes += 1
```

Cuidado com loop infinito: sempre garanta que a condição se torne False em algum momento.

```
# ERRADO – loop infinito
# while True:
#     print("Isso nunca para")

# CERTO – tem condição de parada
saldo = 1000
anos = 0
while saldo < 2000:
    saldo *= 1.05
    anos += 1
print(f"Leva {anos} anos para dobrar a R$ {saldo:.2f}")
```

4.4 Break e Continue

```
# break – interrompe o loop
for valor in [0.5, 0.7, 1.2, 0.88, 0.67]:
```

```

if valor > 1.0:
    print("Alta detectada! Parando.")
    break
print(f"IPCA: {valor}%")

# continue – pula para a próxima iteração
for valor in [0.5, 0.7, 0.88, 0.67, 0.58, 0.16]:
    if valor < 0.3:
        continue # pula meses de deflação
    print(f"IPCA: {valor}%")

```

Exercícios do Capítulo 4

1. Dada uma lista de PIBs anuais, classifique cada ano como “Recessão” (< 0), “Crescimento fraco” (0-2), “Crescimento forte” (> 2). Use if/elif/else.
2. Use for para simular R\$ 5.000 a 0,8% ao mês por 36 meses. Mostre o saldo a cada 6 meses.
3. Com while, descubra quantos meses leva para R\$ 1.000 virar R\$ 2.000 a 1,2% ao mês.
4. Percorra uma lista de inflações e pare ao encontrar a primeira acima de 1%.

Capítulo 5 — Funções

5.1 Definindo funções

```

def nome_da_funcao(parametro1, parametro2):
    """Docstring: explica o que a função faz"""
    resultado = parametro1 + parametro2
    return resultado

```

5.2 Função simples

```

def media_aritmetica(dados):
    """Calcula a média aritmética de uma lista"""
    return sum(dados) / len(dados)

inflacoes = [0.5, 0.7, 0.88, 0.67, 0.58, 0.16]
print(f"Média: {media_aritmetica(inflacoes):.2f}%")

```

5.3 Múltiplos parâmetros

```
def juros_compostos(principal, taxa, periodos):
    """Calcula montante final de juros compostos"""
    return principal * (1 + taxa) ** periodos

montante = juros_compostos(1000, 0.01, 12)
print(f"Montante: R$ {montante:.2f}")
```

5.4 Parâmetros com valor padrão

```
def pib_per_capita(pib_total, populacao, unidade="mil"):
    """Calcula PIB per capita"""
    resultado = pib_total / populacao
    if unidade == "mil":
        return resultado / 1000
    elif unidade == "unidade":
        return resultado
    return resultado

# Chamadas possíveis:
pib_per_capita(2e12, 214e6)          # usa "mil" (padrão)
pib_per_capita(2e12, 214e6, "unidade") # explicita
pib_per_capita(2e12, 214e6, unidade="unidade") # nomeando
```

5.5 Retorno múltiplo

```
def estatisticas(dados):
    """Retorna média, mínimo e máximo"""
    media = sum(dados) / len(dados)
    minimo = min(dados)
    maximo = max(dados)
    return media, minimo, maximo

inf = [0.5, 0.7, 0.88, 0.67, 0.58, 0.16]
media, min_inf, max_inf = estatisticas(inf)
print(f"Média: {media:.2f}, Mín: {min_inf:.2f}, Máx: {max_inf:.2f}")
```

5.6 Função como argumento

```
def aplicar_a_cada(lista, funcao):
    """Aplica uma função a cada elemento da lista"""
    return [funcao(x) for x in lista]

def dobrar(x):
    return x * 2
```

```
resultado = aplicar_a_cada([1, 2, 3], dobrar)
print(resultado) # [2, 4, 6]
```

5.7 Funções lambda (anônimas)

```
# Lambda é uma função sem nome, em uma linha
quadrado = lambda x: x ** 2
print(quadrado(5)) # 25

# Útil com sorted, filter, map
paises = [("Brasil", 2.2), ("Argentina", -1.8), ("Chile", 3.1)]
ordenado = sorted(paises, key=lambda x: x[1]) # ordena pelo PIB
print(ordenado) # [("Argentina", -1.8), ("Brasil", 2.2), ("Chile", 3.1)]
```

Exercícios do Capítulo 5

1. Crie uma função `inflacao_acumulada` que recebe uma lista de taxas mensais e retorna a acumulada.
2. Crie `curva_laffer` que recebe alíquota e retorna arrecadação = alíquota * base * (1 - alíquota). Encontre a alíquota ótima.
3. Crie `classificar_pais` que recebe PIB e inflação e retorna:
 - “Bom” se PIB > 2 e inflação < 5
 - “Atenção” se um dos dois está ruim
 - “Crítico” se ambos estão ruins
4. Use `sorted` com lambda para ordenar países por inflação decrescente.

Capítulo 6 — List Comprehension e Ferramentas

6.1 List comprehension

Cria listas de forma concisa:

```
# [expressao for item in iteravel if condicao]

# Básico
quadrados = [x ** 2 for x in range(10)]
# [0, 1, 4, 9, 16, 25, 36, 49, 64, 81]

# Com filtro
```

```
pares = [x for x in range(20) if x % 2 == 0]

# Aplicação econômica
inflacoes = [0.5, 0.7, 0.88, 0.67, 0.58, 0.16]
acima_media = [x for x in inflacoes if x > sum(inflacoes) / len(inflacoes)]

# Transformação
taxas_reais = [selic - ipca for selic, ipca in zip(selic_list, ipca_list)]

# Dicionário comprehension
quadrados_dict = {x: x ** 2 for x in range(5)}
# {0: 0, 1: 1, 2: 4, 3: 9, 4: 16}
```

6.2 zip — juntar listas

```
países = ["Brasil", "Chile", "Argentina"]
pibs = [2.2, 3.1, -1.8]

for país, pib in zip(países, pibs):
    print(f"{país}: {pib}%")

# Criar dicionário a partir de duas listas
dic = dict(zip(países, pibs))
```

6.3 enumerate — índice + valor

```
for i, valor in enumerate(inflacoes, start=1):
    print(f"Mês {i}: {valor}%")
```

6.4 map e filter

```
# map – aplica função a cada elemento
def ao_quadrado(x):
    return x ** 2

list(map(ao_quadrado, [1, 2, 3])) # [1, 4, 9]
list(map(lambda x: x ** 2, [1, 2, 3])) # [1, 4, 9]

# filter – filtra elementos
list(filter(lambda x: x > 0, [-1, 2, -3, 4])) # [2, 4]
```

6.5 any e all

```
# any – True se pelo menos um elemento for True
# all – True se todos os elementos forem True

dados = [True, False, True]
```

```
any(dados) # True
all(dados) # False

# Aplicação: verificar se algum país está em recessão
pibs = [2.2, -1.8, 3.1]
any(p < 0 for p in pibs) # True
all(p > 0 for p in pibs) # False
```

Exercícios do Capítulo 6

1. Use list comprehension para criar lista de PIBs acima da média.
 2. Use `zip` para criar dicionário de países -> inflação.
 3. Use `enumerate` para exibir “País 1: Brasil (2.2%)”.
 4. Use `filter` para extrair apenas valores positivos de uma lista.
-

Parte II — pandas para Análise de Dados

Capítulo 7 — Introdução ao pandas

7.1 O que é pandas?

pandas é a biblioteca para manipulação de dados tabulares. Os dois objetos principais:

- **Series**: uma coluna (vetor com índice)
- **DataFrame**: tabela completa (várias colunas)

```
import pandas as pd
import numpy as np
```

7.2 Criando DataFrames

A partir de dicionário

```
dados = {
    "pais": ["Brasil", "Argentina", "Chile", "Colômbia", "Peru"],
    "pib_2024": [3.2, -1.8, 2.5, 1.8, 3.0],
    "inflacao": [4.5, 98.0, 3.8, 7.2, 2.0],
    "populacao_milhoes": [214, 46, 19, 52, 34],
    "regiao": ["América do Sul"] * 5
}

df = pd.DataFrame(dados)
print(df)
```

Saída:

	pais	pib_2024	inflacao	populacao_milhoes	regiao
0	Brasil	3.2	4.5	214	América do Sul
1	Argentina	-1.8	98.0	46	América do Sul
2	Chile	2.5	3.8	19	América do Sul
3	Colombia	1.8	7.2	52	América do Sul
4	Peru	3.0	2.0	34	América do Sul

A partir de arquivos

```
# CSV
df = pd.read_csv("dados.csv")
df = pd.read_csv("dados.csv", decimal=".", sep=";") # formato brasileiro

# Excel
df = pd.read_excel("dados.xlsx", sheet_name="Planilha1")

# Clipboard (copie do Excel e rode)
df = pd.read_clipboard()
```

A partir de API do BCB

```
from bcb import sgs

# Códigos SGS: IPCA=433, SELIC=11, Desemprego=24369, Câmbio=1
df = sgs.get({"IPCA": 433, "SELIC": 11}, start="2020-01-01")
print(df.head())
```

7.3 Explorando o DataFrame

```
df.head()           # primeiras 5 linhas
df.head(10)         # primeiras 10
df.tail(3)          # últimas 3
df.sample(5)        # 5 amostras aleatórias

df.shape            # (linhas, colunas)
df.info()           # tipos + nulos + memória
df.describe()       # estatísticas descritivas
df.describe(include="object") # para colunas de texto

df.dtypes           # tipo de cada coluna
df.columns          # nomes das colunas
df.index            # índice
df.values           # matriz numpy subjacente

df["pais"].unique() # valores únicos
df["pais"].nunique() # quantidade de valores únicos
df["pais"].value_counts() # contagem de cada valor

df.isnull().sum()   # valores nulos por coluna
df.duplicated().sum() # linhas duplicadas
```

7.4 O atributo dtype

Cada coluna tem um tipo:

dtype	Significado
int64	Inteiro
float64	Decimal
object	Texto (string)
datetime64	Data/hora
bool	Booleano

```
# Converter tipos
df["pib_2024"] = df["pib_2024"].astype(float)
df["data"] = pd.to_datetime(df["data"])
```

Exercícios do Capítulo 7

1. Crie um DataFrame com 5 países e 4 indicadores.
2. Use `describe()` e interprete as estatísticas.
3. Use `value_counts()` em uma coluna categórica.
4. Verifique se há valores nulos.

Capítulo 8 — Seleção e Filtragem

8.1 Selecionando colunas

```
# Uma coluna (retorna Series)
df["pais"]
df.pais # atalho (funciona se nome não tiver espaço)

# Várias colunas (retorna DataFrame)
df[["pais", "pib_2024"]]
```

8.2 Selecionando linhas por posição (iloc)

```
df.iloc[0]      # primeira linha
df.iloc[-1]     # última linha
df.iloc[0:3]    # linhas 0, 1, 2
df.iloc[[0, 2]] # linhas 0 e 2

df.iloc[0, 1]   # linha 0, coluna 1
```

```
df.iloc[0:3, 0:2] # linhas 0-2, colunas 0-1
df.iloc[:, 0:2]   # todas linhas, colunas 0-1
```

8.3 Selecionando linhas por rótulo (loc)

```
# Primeiro: definir índice
df.index = ["BR", "AR", "CL", "CO", "PE"]

df.loc["BR"]          # linha Brasil
df.loc["BR":"CL"]     # BR, AR, CL (inclusive)
df.loc[["BR", "CL"]]  # BR e CL
df.loc[:, "pais"]     # todas linhas, coluna "pais"
df.loc["BR", "pib_2024"] # valor específico
```

8.4 Filtrando linhas (a operação MAIS importante)

```
# Sintaxe: df[condicao]
# A condição é uma Series de True/False

# Filtro simples
df[df["pib_2024"] > 2.0]          # PIB > 2%
df[df["inflacao"] < 10]         # inflação baixa
df[df["pais"] == "Brasil"]      # apenas Brasil

# Múltiplas condições
df[(df["pib_2024"] > 0) & (df["inflacao"] < 10)]
df[(df["pib_2024"] < 0) | (df["inflacao"] > 10)]

# isin – vários valores
df[df["pais"].isin(["Brasil", "Chile"])]

# between – intervalo
df[df["populacao_milhoes"].between(20, 100)]

# str.contains – texto
df[df["pais"].str.contains("il")] # "Brasil", "Chile"

# Negação
df[~(df["pais"] == "Brasil")]

# query (sintaxe alternativa, útil em strings longas)
df.query("pib_2024 > 0 and inflacao < 10")
```

8.5 Como funciona por baixo

```
mascara = df["pib_2024"] > 2.0
print(mascara)
# 0    True
# 1   False
# 2    True
```

```
# 3    False
# 4     True

df[mascara] # aplica o filtro
```

Exercícios do Capítulo 8

1. Selecione apenas países com inflação menor que 5%.
2. Selecione países com PIB positivo E inflação menor que 10%.
3. Use `iloc` para extrair as últimas 3 linhas.
4. Use `query` para filtrar países com PIB > 2 e população > 30 milhões.

Capítulo 9 — Transformação de Dados

9.1 Criando colunas

```
# Aritmética simples
df["pib_per_capita"] = df["pib_2024"] / df["populacao_milhoes"] * 1000

# Transformação
df["log_pop"] = np.log(df["populacao_milhoes"])
df["pib_categoria"] = df["pib_2024"].apply(lambda x: "Alto" if x > 2 else "Baixo")

# with columns (útil para múltiplas)
df = df.assign(
    pib_dobro=df["pib_2024"] * 2,
    inflacao_decimal=df["inflacao"] / 100
)
```

9.2 Apply — aplicando funções

```
# Apply em coluna
def classificar_inflacao(x):
    if x > 10: return "Hiper"
    elif x > 5: return "Alta"
    elif x > 2: return "Moderada"
    else: return "Baixa"

df["categoria_inflacao"] = df["inflacao"].apply(classificar_inflacao)

# Apply em DataFrame (por linha)
df[["pib_2024", "inflacao"]].apply(lambda x: x.mean(), axis=1) # média por linha
```

9.3 Renomeando colunas

```
df.rename(columns={"pib_2024": "crescimento_pib"}, inplace=True)
df.columns = [c.upper() for c in df.columns] # tudo maiúsculo
```

9.4 Removendo colunas e linhas

```
# Remover colunas
df.drop("coluna_que_nao_quero", axis=1, inplace=True)
df.drop(["col1", "col2"], axis=1, inplace=True)

# Remover linhas
df.drop([0, 2], inplace=True) # remove índices 0 e 2
df.drop(df[df["pib_2024"] < 0].index, inplace=True) # remove recessão
```

9.5 Valores nulos

```
# Verificar
df.isnull().sum()
df.isna().sum() # mesmo que isnull

# Remover
df.dropna() # remove qualquer linha com nulo
df.dropna(subset=["pib_2024"]) # remove só se coluna específica for nula
df.dropna(thresh=3) # remove se tiver menos de 3 não-nulos

# Preencher
df.fillna(0) # com zero
df.fillna(df.mean()) # com a média da coluna
df["coluna"].fillna(method="ffill") # último valor válido (forward fill)
df["coluna"].fillna(method="bfill") # próximo valor válido (backward fill)
```

9.6 Ordenação

```
# Por valor
df.sort_values("pib_2024") # crescente
df.sort_values("pib_2024", ascending=False) # decrescente
df.sort_values(["regiao", "pib_2024"]) # múltiplas colunas

# Por índice
df.sort_index()
```

9.7 Amostragem

```
df.sample(5)           # 5 amostras aleatórias
df.sample(frac=0.1)     # 10% das linhas
df.sample(5, random_state=42) # reprodutível
```

Exercícios do Capítulo 9

1. Crie coluna `pib_per_capita = pib / populacao * 1000`.
2. Classifique países: “Grande” se população > 50 milhões, “Médio” se > 20, “Pequeno” caso contrário.
3. Preencha valores nulos com a média da coluna.
4. Ordene o DataFrame por inflação decrescente.

Capítulo 10 — Datas e Séries Temporais

10.1 Convertendo para datetime

```
df["data"] = pd.to_datetime(df["data"])
```

Estratégias comuns de conversão:

```
# Formatos comuns
pd.to_datetime("2024-01-15")           # yyyy-mm-dd
pd.to_datetime("15/01/2024", dayfirst=True) # dd/mm/yyyy
pd.to_datetime("Jan 15 2024")
pd.to_datetime("20240115", format="%Y%m%d") # formato explícito

# Erro: misturar formatos
# use errors="coerce" para converter o que der e virar NaT no resto
pd.to_datetime(coluna, errors="coerce")
```

10.2 Extraindo componentes

```
df["ano"] = df["data"].dt.year
df["mes"] = df["data"].dt.month
df["dia"] = df["data"].dt.day
df["trimestre"] = df["data"].dt.quarter
df["semestre"] = df["data"].dt.semester
df["semana"] = df["data"].dt.isocalendar().week
```

```
df["dia_semana"] = df["data"].dt.dayofweek # 0=segunda, 6=domingo
df["nome_mes"] = df["data"].dt.month_name("pt_BR")
```

10.3 Indexando por data

```
df.set_index("data", inplace=True)
df = df.sort_index() # sempre ordene o índice

# Fatiamento temporal
df.loc["2024"] # ano inteiro
df.loc["2024-01":"2024-06"] # primeiro semestre
df.loc["2024-01-15":] # a partir de 15/01/2024

# Condições com datas
df[df.index.year >= 2023]
df[df.index.month == 12] # apenas dezembros
```

10.4 Reamostragem (resample)

Muda a frequência dos dados.

```
# Agregar por período
df.resample("Y").mean() # anual (year)
df.resample("Q").mean() # trimestral (quarter)
df.resample("M").mean() # mensal (month)
df.resample("W").mean() # semanal (week)
df.resample("D").mean() # diário

# Agregações diferentes
df.resample("Y").agg({
    "pib": "mean",
    "inflacao": "max",
    "desemprego": "last"
})
```

10.5 Lag, diferença e variação percentual

Essenciais para séries temporais.

```
# Lag (valor do período anterior)
df["pib_lag1"] = df["pib"].shift(1)
df["pib_lag2"] = df["pib"].shift(2)

# Diferença absoluta
df["pib_diff"] = df["pib"].diff() # pib_t - pib_{t-1}

# Variação percentual
df["pib_pct"] = df["pib"].pct_change() * 100 # em %

# Média móvel
```

```
df["pib_mm3"] = df["pib"].rolling(window=3).mean()
df["pib_mm12"] = df["pib"].rolling(window=12).mean()

# Desvio padrão móvel
df["pib_vol"] = df["pib"].rolling(window=12).std()
```

10.6 Aplicação completa

```
from bcb import sgs

# Baixar IPCA de 2010 a 2026
ipca = sgs.get({"IPCA": 433}, start="2010-01-01")
ipca.columns = ["ipca"]
ipca.index = pd.to_datetime(ipca.index)

# Criar features temporais
df = ipca.copy()
df["ano"] = df.index.year
df["mes"] = df.index.month
df["trimestre"] = df.index.quarter

# Lags e médias
df["ipca_lag1"] = df["ipca"].shift(1)
df["ipca_mm12"] = df["ipca"].rolling(12).mean()
df["ipca_acum"] = (1 + df["ipca"] / 100).cumprod() - 1
df["ipca_acum"] *= 100

print(df.tail(12))
```

Exercícios do Capítulo 10

1. Baixe SELIC de 2015 a 2026. Calcule média móvel de 6 e 12 meses.
2. Baixe IPCA e calcule inflação acumulada em 12 meses (`.rolling(12).sum()`).
3. Crie coluna com a diferença da SELIC mês a mês.
4. Reamostre IPCA para frequência trimestral com média.
5. Extraia apenas meses de dezembro de todos os anos e calcule a inflação média de dezembro.

Capítulo 11 — Agrupamento e Junção de Tabelas

11.1 Groupby — tabelas dinâmicas

```
# Criando dados para exemplo
np.random.seed(42)
dados = {
```

```

        "ano": np.repeat(range(2020, 2025), 3),
        "pais": ["Brasil", "Chile", "Argentina"] * 5,
        "pib": np.random.uniform(-2, 5, 15),
        "inflacao": np.random.uniform(2, 15, 15)
    }
    df = pd.DataFrame(dados)

    # Agregar por uma coluna
    df.groupby("pais")["pib"].mean()
    df.groupby("pais")["inflacao"].agg(["mean", "std", "min", "max"])

    # Múltiplas colunas
    df.groupby(["ano", "pais"])["pib"].mean()

    # Várias agregações simultâneas
    df.groupby("pais").agg({
        "pib": ["mean", "std", "count"],
        "inflacao": "mean"
    })

    # Achatando colunas
    agrupado = df.groupby("pais").agg(
        pib_medio=("pib", "mean"),
        pib_std=("pib", "std"),
        inflacao_medio=("inflacao", "mean")
    )

```

11.2 Merge — juntando tabelas

Equivalente ao JOIN do SQL ou PROCX do Excel.

```

pib_df = pd.DataFrame({
    "pais": ["Brasil", "Argentina", "Chile", "Peru"],
    "pib": [2.2, -1.8, 3.1, 2.5],
    "ano": [2024, 2024, 2024, 2024]
})

inf_df = pd.DataFrame({
    "pais": ["Brasil", "Chile", "Peru", "Uruguai"],
    "inflacao": [4.5, 3.8, 2.0, 5.5],
    "ano": [2024, 2024, 2024, 2024]
})

# Inner (só interseção)
inner = pd.merge(pib_df, inf_df, on="pais") # 3 países: Brasil, Chile, Peru

# Left (tudo da esquerda)
left = pd.merge(pib_df, inf_df, on="pais", how="left")

# Right (tudo da direita)
right = pd.merge(pib_df, inf_df, on="pais", how="right")

# Outer (tudo de ambos)
outer = pd.merge(pib_df, inf_df, on="pais", how="outer")

# Quando as chaves têm nomes diferentes
pib_df2 = pib_df.rename(columns={"pais": "nome_pais"})

```

```
merged = pd.merge(pib_df2, inf_df, left_on="nome_pais", right_on="pais")

# Múltiplas chaves
pd.merge(pib_df, inf_df, on=["pais", "ano"])
```

11.3 Concatenando DataFrames

```
# Empilhar verticalmente (mais linhas)
df1 = pd.DataFrame({"pais": ["A", "B"], "pib": [1, 2]})
df2 = pd.DataFrame({"pais": ["C", "D"], "pib": [3, 4]})
pd.concat([df1, df2], ignore_index=True)

# Empilhar horizontalmente (mais colunas)
pd.concat([df1, df2], axis=1)
```

Exercícios do Capítulo 11

1. Crie dois DataFrames (PIB e inflação de 5 países) e faça inner, left, right e outer merge.
2. Use groupby para calcular PIB médio por região (crie uma coluna “regiao”).
3. Calcule o desvio padrão do PIB por ano.
4. Junte dados de PIB e inflação por país e ano, depois calcule a correlação.

Capítulo 12 — Acessando Dados Econômicos Reais

12.1 BCB SGS (Sistema Gerenciador de Séries Temporais)

```
from bcb import sgs

# Códigos comuns
codigos = {
    "IPCA": 433,
    "SELIC": 11,
    "CAMBIO": 1,
    "DESEMPREGO": 24369,
    "PIB_MENSAL": 4380,
}

# Baixar múltiplos
dados = sgs.get(codigos, start="2020-01-01")
```

Onde encontrar códigos: - <https://www3.bcb.gov.br/sgspub/> - Pesquise por nome da série

12.2 Banco Mundial (WDI)

```
# Via pandas_datareader (precisa instalar)
# pip install pandas_datareader

from pandas_datareader import wb

# Indicadores comuns
# NY.GDP.PCAP.PP.KD: PIB per capita PPP
# FP.CPI.TOTL.ZG: Inflação
# SL.UEM.TOTL.ZS: Desemprego

indicadores = ["NY.GDP.PCAP.PP.KD", "FP.CPI.TOTL.ZG", "SL.UEM.TOTL.ZS"]
países = ["BR", "CL", "AR", "CO", "PE"]

df = wb.download(country=países, indicator=indicadores,
                  start=2010, end=2024)
```

12.3 Ipeadata (dados brasileiros históricos)

```
# Requer requests + parsing manual
# Alternativa: usar arquivos do site do Ipeadata
```

12.4 FMI (IMF Data)

```
# Via imfpy ou acesso direto ao JSON
```

Exercícios do Capítulo 12

1. Baixe IPCA, SELIC e PIB mensal do BCB de 2010 a 2026.
2. Crie um DataFrame único com os três.
3. Calcule juro real (SELIC - IPCA acumulado 12m).
4. Salve em CSV com ponto e vírgula e vírgula como decimal.

Parte III — Visualização de Dados

Capítulo 13 — matplotlib

13.1 Filosofia

matplotlib tem duas APIs: - **pyplot** (`plt.plot()`) — rápida, para exploração - **OOP** (`fig, ax = plt.subplots()`) — explícita, para gráficos finais

Sempre prefira a OOP.

13.2 Gráfico de linha

```
import matplotlib.pyplot as plt
from bcb import sgs

ipca = sgs.get({"IPCA": 433}, start="2020-01-01")

fig, ax = plt.subplots(figsize=(12, 5))
ax.plot(ipca.index, ipca["IPCA"], color="crimson", linewidth=1.5)
ax.set_title("IPCA - Variação Mensal (%)", fontsize=14)
ax.set_ylabel("%")
ax.grid(True, alpha=0.3)
fig.tight_layout()
```

13.3 Parâmetros do plot

```
ax.plot(x, y,
        color="crimson",          # nome, hex (#FF5733), RGB ((1, 0, 0))
        linewidth=2,              # espessura
        linestyle="-",            # "-" sólida, "--" tracejada, ":" pontilhada,
                                   # "-." traço-ponto
        marker="o",               # "o" círculo, "s" quadrado, "^" triângulo
        markersize=6,
        alpha=0.8,                 # transparência
        label="IPCA"              # legenda
    )
```

13.4 Personalização completa

```
fig, ax = plt.subplots(figsize=(12, 5.5))

ax.plot(ipca.index, ipca["IPCA"], color="crimson", linewidth=1.2, label="IPCA")
ax.axhline(0, color="gray", linewidth=0.5)
ax.axhline(ipca.mean().iloc[0], color="blue", linestyle="--", alpha=0.5, label="Média")

ax.set_title("Brasil: IPCA Mensal (2020-2026)", fontsize=14, fontweight="bold")
ax.set_ylabel("Variação mensal (%)", fontsize=12)
ax.legend(frameon=True, fancybox=True, shadow=True, fontsize=10)

ax.grid(True, alpha=0.3, linestyle=":")
ax.set_axisbelow(True)

ax.spines["top"].set_visible(False)
ax.spines["right"].set_visible(False)

fig.tight_layout()
fig.savefig("ipca_final.png", dpi=300, bbox_inches="tight")
```

13.5 Dois eixos Y

```
from bcb import sgs

ipca = sgs.get({"IPCA": 433}, start="2020-01-01")
selic = sgs.get({"SELIC": 11}, start="2020-01-01")

fig, ax1 = plt.subplots(figsize=(12, 5))

ax1.plot(ipca.index, ipca["IPCA"], color="crimson", linewidth=1.5, label="IPCA")
ax1.set_ylabel("IPCA (%)", color="crimson", fontsize=12)
ax1.tick_params(axis="y", labelcolor="crimson")

ax2 = ax1.twinx()
ax2.plot(selic.index, selic["SELIC"], color="navy", linewidth=1.5, label="SELIC")
ax2.set_ylabel("SELIC (%)", color="navy", fontsize=12)
ax2.tick_params(axis="y", labelcolor="navy")

ax1.set_title("IPCA e SELIC (2020-2026)", fontsize=14)
ax1.grid(True, alpha=0.3)
fig.tight_layout()
```

13.6 Subplots

```
fig, axes = plt.subplots(2, 2, figsize=(14, 8))
axes = axes.flatten()

# Gráfico 1
axes[0].plot(ipca.index, ipca["IPCA"], color="crimson")
axes[0].set_title("IPCA")
```

```
# Gráfico 2
axes[1].plot(selic.index, selic["SELIC"], color="navy")
axes[1].set_title("SELIC")

# Gráfico 3
axes[2].hist(ipca["IPCA"], bins=30, color="steelblue", edgecolor="black")
axes[2].set_title("Distribuição IPCA")

# Gráfico 4
axes[3].boxplot(ipca["IPCA"])
axes[3].set_title("Boxplot IPCA")

for ax in axes:
    ax.grid(True, alpha=0.3)

fig.tight_layout()
```

13.7 Fill between

```
fig, ax = plt.subplots(figsize=(12, 5))
ax.plot(ipca.index, ipca["IPCA"], color="crimson", linewidth=1.5)
ax.fill_between(ipca.index, ipca["IPCA"], 0,
                where=(ipca["IPCA"] > 0).values,
                color="green", alpha=0.1, label="Inflação positiva")
ax.fill_between(ipca.index, ipca["IPCA"], 0,
                where=(ipca["IPCA"] < 0).values,
                color="red", alpha=0.1, label="Deflação")
ax.legend()
ax.grid(True, alpha=0.3)
```

Capítulo 14 — seaborn

14.1 Por que seaborn

Gráficos estatísticos mais bonitos com menos código.

```
import seaborn as sns

sns.set_theme(style="whitegrid")
```

14.2 Regplot — scatter + regressão

```
sns.regplot(data=df, x="educacao", y="pib_per_capita",
            scatter_kws={"alpha": 0.6}, line_kws={"color": "red"})
```

14.3 Pairplot — correlações de uma vez

```
sns.pairplot(df[["pib", "inflacao", "desemprego", "populacao"]])
```

14.4 Boxplot comparativo

```
sns.boxplot(data=df, x="regiao", y="pib")
```

Capítulo 15 — Gráficos para Economia

15.1 Publication-ready

```
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker
from bcb import sgs
import seaborn as sns

sns.set_theme(style="whitegrid")

ipca = sgs.get({"IPCA": 433}, start="2000-01-01")
selic = sgs.get({"SELIC": 11}, start="2000-01-01")

fig, ax = plt.subplots(figsize=(12, 5.5))

ax.plot(ipca.index, ipca["IPCA"], color="#CC3311",
        linewidth=1.2, label="IPCA", alpha=0.85)
ax.plot(selic.index, selic["SELIC"], color="#0077BB",
        linewidth=1.2, label="SELIC", alpha=0.85)

ax.fill_between(ipca.index, ipca["IPCA"], 0,
               alpha=0.05, color="#CC3311")

ax.axhline(0, color="gray", linewidth=0.5)
ax.set_title("Brasil: Taxa SELIC e Inflação (IPCA) – 2000 a 2026",
            fontsize=14, fontweight="bold", pad=12)
ax.set_ylabel("Percentual (%)", fontsize=12)
ax.legend(fontsize=11, frameon=True, fancybox=True)

ax.xaxis.set_major_locator(ticker.MultipleLocator(2))
ax.xaxis.set_major_formatter(ticker.DateFormatter("%Y"))

ax.grid(True, alpha=0.25, linestyle=":")
ax.set_axisbelow(True)

ax.spines["top"].set_visible(False)
ax.spines["right"].set_visible(False)

fig.tight_layout()
```

```
fig.savefig("publication_ready.png", dpi=300, bbox_inches="tight")  
plt.close()
```

15.2 Cores seguras para daltônicos

```
cores = ["#0077BB", "#33BBEE", "#EE7733",  
         "#CC3311", "#009988", "#BBBBBB"]
```

Parte IV — Econometria

Capítulo 16 — Regressão Linear

16.1 Modelo OLS com statsmodels

```
import statsmodels.api as sm
import numpy as np
import pandas as pd

# Dados: Consumo Keynesiano
np.random.seed(42)
renda = np.arange(1000, 11000, 1000)
consumo = 200 + 0.8 * renda + np.random.normal(0, 80, len(renda))

df = pd.DataFrame({"renda": renda, "consumo": consumo})

# Estimar: consumo =  $\beta_0 + \beta_1 * renda$ 
X = sm.add_constant(df["renda"])
y = df["consumo"]

modelo = sm.OLS(y, X).fit()
print(modelo.summary())
```

16.2 Extraindo resultados

modelo.params	# [const, renda]
modelo.pvalues	# p-valores
modelo.rsquared	# R^2
modelo.rsquared_adj	# R^2 ajustado
modelo.resid	# resíduos
modelo.fittedvalues	# valores preditos
modelo.conf_int()	# intervalo de confiança (95%)
modelo.bse	# erro padrão
modelo.aic	# AIC
modelo.bic	# BIC
modelo.nobs	# número de observações
modelo.df_resid	# graus de liberdade
modelo.fvalue	# estatística F
modelo.f_pvalue	# p-valor do F

16.3 Regressão múltipla

```
# Consumo ~ renda + riqueza + juros
df["riqueza"] = renda * 3 + np.random.normal(0, 500, len(renda))
df["juros"] = 5 + np.random.normal(0, 1, len(renda))

X = sm.add_constant(df[["renda", "riqueza", "juros"]])
y = df["consumo"]

modelo = sm.OLS(y, X).fit()
print(modelo.summary())
```

16.4 Regressão com fórmula

```
import statsmodels.formula.api as smf

modelo = smf.ols("consumo ~ renda + riqueza + juros", data=df).fit()
```

16.5 Curva de Phillips com dados reais

```
from bcb import sgs

# IPCA e Desemprego
ipca = sgs.get({"IPCA": 433}, start="2012-01-01")
desemprego = sgs.get({"DESEMPREGO": 24369}, start="2012-01-01")

df = pd.merge(ipca, desemprego, on="Date").dropna()
df.columns = ["ipca", "desemprego"]

# Com lag da inflação
df["ipca_lag1"] = df["ipca"].shift(1)
df = df.dropna()

modelo = smf.ols("ipca ~ desemprego + ipca_lag1", data=df).fit()
print(modelo.summary())
print(f"\nCoef. desemprego: {modelo.params['desemprego']:.4f}")
print(f"P-valor: {modelo.pvalues['desemprego']:.4f}")
```

Capítulo 17 — Diagnóstico e Validação

17.1 Normalidade dos resíduos

```
from scipy import stats
```

```

residuos = modelo.resid

# Teste Jarque-Bera
jb = stats.jarque_bera(residuos)
print(f"Jarque-Bera: {jb[0]:.4f} (p-valor: {jb[1]:.4f})")
# H0: resíduos normais. Se p > 0.05, não rejeita normalidade

# Teste de Shapiro-Wilk (mais poderoso)
sw = stats.shapiro(residuos)
print(f"Shapiro-Wilk: {sw[0]:.4f} (p-valor: {sw[1]:.4f})")

# Q-Q plot
fig, ax = plt.subplots(figsize=(6, 6))
stats.probplot(residuos, dist="norm", plot=ax)

```

17.2 Heterocedasticidade

```

from statsmodels.stats.diagnostic import het_breuschpagan

bp = het_breuschpagan(residuos, modelo.model.exog)
nomes = ["LM Stat", "LM p-valor", "F Stat", "F p-valor"]
print(dict(zip(nomes, [round(v, 4) for v in bp])))

# H0: homocedasticidade. Se p < 0.05, há heterocedasticidade

```

17.3 Autocorrelação

```

from statsmodels.stats.stattools import durbin_watson

dw = durbin_watson(residuos)
print(f"Durbin-Watson: {dw:.4f}")
# 2 = sem autocorrelação
# < 1.5 = autocorrelação positiva
# > 2.5 = autocorrelação negativa

# Ljung-Box (teste para autocorrelação em lags específicos)
from statsmodels.stats.diagnostic import acorr_ljungbox
lb = acorr_ljungbox(residuos, lags=[6, 12, 24])
print(lb)

```

17.4 Multicolinearidade (VIF)

```

from statsmodels.stats.outliers_influence import variance_inflation_factor

X = df[["desemprego", "ipca_lag1"]]
X = sm.add_constant(X)

vif = pd.DataFrame()
vif["variavel"] = X.columns
vif["VIF"] = [variance_inflation_factor(X.values, i) for i in range(X.shape[1])]

```

```
print(vif)
# VIF > 10 indica multicolinearidade severa
```

17.5 Erros padrão robustos

```
# HC0 = White, HC1 = ajustado por graus de liberdade
modelo_robusto = modelo.get_robustcov_results(cov_type="HC1")
print(modelo_robusto.summary())
```

Capítulo 18 — Séries Temporais

18.1 Estacionariedade (ADF)

```
from statsmodels.tsa.stattools import adfuller

result = adfuller(serie.dropna())
print(f"ADF: {result[0]:.4f}")
print(f"p-valor: {result[1]:.4f}")
print(f"Valores críticos: {result[4]}")

if result[1] < 0.05:
    print("Série estacionária")
else:
    print("Série não estacionária – precisa diferenciar")
```

18.2 ACF e PACF

```
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(12, 8))
plot_acf(serie, lags=24, ax=ax1)
plot_pacf(serie, lags=24, ax=ax2)
```

18.3 ARIMA

```
from statsmodels.tsa.arima.model import ARIMA

modelo = ARIMA(serie, order=(p, d, q))
resultado = modelo.fit()
print(resultado.summary())

# Previsão
```

```
forecast = resultado.forecast(steps=12)
conf_int = resultado.get_forecast(12).conf_int()
```

18.4 SARIMA (sazonal)

```
from statsmodels.tsa.statespace.sarimax import SARIMAX

# SARIMA(p,d,q)(P,D,Q,s) – s=12 para mensal
modelo = SARIMAX(serie,
                  order=(1, 1, 1),
                  seasonal_order=(1, 1, 1, 12),
                  enforce_stationarity=False,
                  enforce_invertibility=False)
resultado = modelo.fit(dispatch=False)
```

18.5 Seleção automática de ordem

```
import itertools

p = range(0, 4)
d = range(0, 2)
q = range(0, 4)

best_aic = float("inf")
best_order = None

for pd_ in p:
    for d_ in d:
        for q_ in q:
            try:
                modelo = ARIMA(serie, order=(pd_, d_, q_))
                resultado = modelo.fit()
                if resultado.aic < best_aic:
                    best_aic = resultado.aic
                    best_order = (pd_, d_, q_)
            except:
                continue

print(f"Melhor ARIMA{best_order}, AIC={best_aic:.2f}")
```

18.6 Cointegração

```
from statsmodels.tsa.stattools import coint

# Teste Engle-Granger
score, pvalue, _ = coint(y1, y2)
print(f"p-valor cointegração: {pvalue:.4f}")
```

```
if pvalue < 0.05:
    print("Séries são cointegradas (relação de longo prazo)")
```

18.7 Modelo VAR

```
from statsmodels.tsa.api import VAR

modelo = VAR(df)
resultado = modelo.fit(maxlags=6, ic="aic")
print(f"Lags ótimos: {resultado.k_ar}")

# Função impulso-resposta
irf = resultado.irf(12)
irf.plot()

# Previsão
forecast = resultado.forecast(df.values[-resultado.k_ar:], steps=6)
```

18.8 Causalidade de Granger

```
from statsmodels.tsa.stattools import grangercausalitytests

gc = grangercausalitytests(df[["y", "x"]], maxlag=6, verbose=False)
for lag in range(1, 7):
    p = gc[lag][0]["ssr_ftest"][1]
    print(f"Lag {lag}: p={p:.4f} {'Causa' if p < 0.05 else 'Não causa'})
```

Capítulo 19 — Dados de Painel

19.1 Estrutura de painel

Dados que acompanham as mesmas unidades (países, estados) ao longo do tempo.

19.2 Pooled OLS

```
# Ignora estrutura de painel
X = sm.add_constant(df[["x1", "x2"]])
modelo = sm.OLS(y, X).fit()
```

19.3 Efeitos Fixos

```
from linearmodels.panel import PanelOLS

df = df.set_index(["pais", "ano"])

modelo = PanelOLS.from_formula(
    "y ~ x1 + x2 + EntityEffects",
    data=df
).fit()
```

19.4 Efeitos Aleatórios

```
from linearmodels.panel import RandomEffects

modelo = RandomEffects.from_formula("y ~ x1 + x2", data=df).fit()
```

19.5 Teste de Hausman

```
from linearmodels.panel import compare

fe = PanelOLS.from_formula("y ~ x1 + EntityEffects", data=df).fit()
re = RandomEffects.from_formula("y ~ x1", data=df).fit()

print(compare({"FE": fe, "RE": re}))
# Se p < 0.05: usar efeitos fixos
# Se p > 0.05: usar efeitos aleatórios
```

Parte V — Projetos

Capítulo 20 — Projeto: Análise Macroeconômica do Brasil

Script completo que baixa dados do BCB, processa e gera relatório.

```
from bcb import sgs
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker

codigos = {
    "IPCA": 433,
    "SELIC": 11,
    "DESEMPREGO": 24369,
    "CAMBIO": 1,
    "PIB": 4380
}

dados = sgs.get(codigos, start="2010-01-01")

# Processar
dados["IPCA_ACUM"] = dados["IPCA"].rolling(12).sum()
dados["JURO_REAL"] = dados["SELIC"] - dados["IPCA_ACUM"]
dados["CAMBIO_VAR"] = dados["CAMBIO"].pct_change() * 100

# Relatório
print("=" * 60)
print("RELATÓRIO MACROECONÔMICO - BRASIL")
print("=" * 60)
ultimos = dados.tail(1)
print(f"Data: {ultimos.index[0].date()}")
print(f"IPCA mensal: {ultimos['IPCA'].values[0]:.2f}%")
print(f"IPCA acum. 12m: {ultimos['IPCA_ACUM'].values[0]:.2f}%")
print(f"SELIC: {ultimos['SELIC'].values[0]:.2f}%")
print(f"Juro real: {ultimos['JURO_REAL'].values[0]:.2f}%")
print(f"Desemprego: {ultimos['DESEMPREGO'].values[0]:.2f}%")
print(f"Câmbio: {ultimos['CAMBIO'].values[0]:.2f}%")

# Gráficos
fig, axes = plt.subplots(3, 2, figsize=(14, 10))
series = [
    ("IPCA (mensal)", "crimson"),
    ("SELIC", "navy"),
    ("IPCA Acum. 12m", "darkred"),
    ("Desemprego", "darkgreen"),
    ("Câmbio (USD/BRL)", "purple"),
    ("Juro Real", "orange")
]
```

```

for ax, (titulo, cor) in zip(axes.flatten(), series):
    ax.plot(dados.index, dados[titulo], color=cor, linewidth=1.2)
    ax.set_title(titulo, fontsize=12)
    ax.grid(True, alpha=0.3)
fig.tight_layout()
fig.savefig("dashboard.png", dpi=200)

```

Capítulo 21 — Projeto: Previsão de Inflação com SARIMA

```

from bcb import sgs
import matplotlib.pyplot as plt
from statsmodels.tsa.statespace.sarimax import SARIMAX

ipca = sgs.get({"IPCA": 433}, start="2005-01-01")
serie = ipca["IPCA"]

train = serie[:-12]
test = serie[-12:]

modelo = SARIMAX(train,
                  order=(1, 1, 1),
                  seasonal_order=(1, 1, 1, 12),
                  enforce_stationarity=False,
                  enforce_invertibility=False)
resultado = modelo.fit(dispatch=False)

forecast = resultado.forecast(steps=12)

from sklearn.metrics import mean_absolute_error
mae = mean_absolute_error(test, forecast)
print(f"MAE: {mae:.2f} pp")

fig, ax = plt.subplots(figsize=(12, 5))
ax.plot(train.index[-60:], train[-60:], label="Histórico")
ax.plot(test.index, test, label="Real", color="green")
ax.plot(forecast.index, forecast, label="Previsão", color="red", linestyle="--")
ax.fill_between(forecast.index,
                resultado.get_forecast(12).conf_int().iloc[:, 0],
                resultado.get_forecast(12).conf_int().iloc[:, 1],
                alpha=0.2, color="red")
ax.legend()
ax.grid(True, alpha=0.3)
fig.tight_layout()
fig.savefig("previsao.png", dpi=150)

```

Capítulo 22 — Projeto Final: Estrutura de TCC

```

meu_tcc/
├─ dados/           # Dados brutos (imutáveis)
├─ scripts/         # Código numerado
└─ 01_baixar.py

```

```
| | | 02_limpeza.py
| | | 03_descritiva.py
| | | 04_modelos.py
| | | 05_graficos.py
| | output/          # Resultados
| | | tabelas/
| | | graficos/
| | environment.yml  # Ambiente replicável
| | README.md
```

Apêndices

Apêndice A — Guia rápido de consulta

Operação	Código
Abrir CSV	<code>pd.read_csv("arquivo.csv")</code>
Filtrar	<code>df[df["col"] > 0]</code>
Agrupar	<code>df.groupby("x")["y"].mean()</code>
Juntar	<code>pd.merge(a, b, on="x")</code>
Lag	<code>df["x"].shift(1)</code>
Média móvel	<code>df["x"].rolling(3).mean()</code>
Regressão	<code>sm.OLS(y, X).fit()</code>
ARIMA	<code>ARIMA(y, order=(p,d,q)).fit()</code>
ADF	<code>adfuller(serie)</code>
Gráfico	<code>ax.plot(x, y)</code>

Apêndice B — Códigos BCB SGS mais usados

Série	Código
IPCA (mensal)	433
IPCA (acum. 12m)	13522
SELIC (meta)	11
SELIC (efetiva)	1178
Câmbio (USD)	1
Desemprego	24369

Série	Código
PIB mensal	4380
Produção industrial	21855
Dívida líquida (%PIB)	4538
Resultado primário	4501

Apêndice C — Soluções dos Exercícios

Capítulo 2

1. `5000 * (1 + 0.015) ** 24`
2. `1000 * 5.45`
3. False, True, True
4. `meta_descumprida = inflacao > 3.5`

Capítulo 3

- 1.

```
pib = [2.2, -1.8, 3.1, 2.8, -0.5]
positivos = [x for x in pib if x > 0]
print(len(positivos), sum(positivos) / len(positivos))
```

- 1.

```
países = {"Brasil": {"inflacao": 4.5}, "Argentina": {"inflacao": 98.0}}
print(abs(países["Brasil"]["inflacao"] - países["Argentina"]["inflacao"]))
```

- 1.

```
ipca = [0.5, 0.7, 0.88, 0.67, 0.58, 0.16]
print(ipca[:3], ipca[-3:], ipca[::-1])
```

1. EUR é a maior. 3 moedas abaixo de R\$ 1. `moedas["JPY"] = 0.036`

Capítulo 4

1. Loop com if/elif/else.

2.

```
saldo = 5000
for mes in range(1, 37):
    saldo *= 1.008
    if mes % 6 == 0:
        print(f"Mês {mes}: R$ {saldo:.2f}")
```

1.

```
saldo = 1000
meses = 0
while saldo < 2000:
    saldo *= 1.012
    meses += 1
print(meses)
```

1.

```
for v in [0.5, 0.7, 0.88, 0.67, 0.58, 0.16]:
    if v > 1:
        print(v)
        break
```

Capítulo 5

1.

```
def inflacao_acumulada(taxas):
    acum = 1
    for t in taxas:
        acum *= (1 + t/100)
    return (acum - 1) * 100
```

1.

```
def curva_laffer(taxa, base=1000):
    return taxa * base * (1 - taxa)
# Ótimo: taxa = 0.5
```

1.

```
def classificar(pib, inf):  
    if pib > 2 and inf < 5: return "Bom"  
    elif pib < 0 and inf > 8: return "Crítico"  
    else: return "Atenção"
```

1.

```
sorted(paises, key=lambda x: x[1], reverse=True)
```

Fim do livro. Lembre-se: teoria sem prática é inútil. Abra o terminal e execute cada exemplo.